

UNIVERSIDADE FEDERAL DE MINAS GERAIS
DEE - DEPARTAMENTO DE ENGENHARIA ELÉTRICA
CURSO DE ENGENHARIA DE SISTEMAS

RAFAEL LIMA CAIRES

**SISTEMA INTELIGENTE PARA ANÁLISE PREDITIVA E
RECOMENDAÇÃO DE ESTRATÉGIAS PARA O MERCADO DE
RENDA VARIÁVEL**

TRABALHO DE CONCLUSÃO DE CURSO

MINAS GERAIS
2025

RAFAEL LIMA CAIRES

**SISTEMA INTELIGENTE PARA ANÁLISE PREDITIVA E
RECOMENDAÇÃO DE ESTRATÉGIAS PARA O MERCADO DE
RENDA VARIÁVEL**

Trabalho de Conclusão de Curso apresentado ao Curso de Engenharia de Sistemas da Universidade Federal de Minas Gerais, como requisito parcial para a obtenção do título de bacharel em Engenharia de Sistemas.

Orientadora: Gabriela Nunes Lopes
Universidade Federal de Minas Gerais

MINAS GERAIS
2025

Altere este texto inserindo a dedicatória do seu trabalho.

AGRADECIMENTOS

Edite e coloque aqui os agradecimentos às pessoas e/ou instituições que contribuíram para a realização do trabalho.

É obrigatório o agradecimento às instituições de fomento à pesquisa que financiaram total ou parcialmente o trabalho, inclusive no que diz respeito à concessão de bolsas.

Eu denomino meu campo de Gestão do Conhecimento, mas você não pode gerenciar conhecimento. Ninguém pode. O que pode fazer - o que a empresa pode fazer - é gerenciar o ambiente que otimize o conhecimento. (PRUSAK, Laurence, 1997).

RESUMO

SOBRENOME, Nome. Sistema Inteligente para Análise Preditiva e Recomendação de Estratégias para o Mercado de Renda Variável. 2025. 34 f. Trabalho de Conclusão de Curso – Curso de Engenharia de Sistemas, Universidade Federal de Minas Gerais. Minas Gerais, 2025.

O Resumo é um elemento obrigatório em tese, dissertação, monografia e TCC, constituído de uma sequência de frases concisas e objetivas, fornecendo uma visão rápida e clara do conteúdo do estudo. O texto deverá conter no máximo 500 palavras e ser antecedido pela referência do estudo. Também, não deve conter citações. O resumo deve ser redigido em parágrafo único, espaçamento simples e seguido das palavras representativas do conteúdo do estudo, isto é, palavras-chave, em número de três a cinco, separadas entre si por ponto e finalizadas também por ponto. Usar o verbo na terceira pessoa do singular, com linguagem impessoal, bem como fazer uso, preferencialmente, da voz ativa. Texto contendo um único parágrafo.

Palavras-chave: Palavra. Segunda Palavra. Outra palavra.

ABSTRACT

SOBRENOME, Nome. Title in English. 2025. 34 f. Trabalho de Conclusão de Curso – Curso de Engenharia de Sistemas, Universidade Federal de Minas Gerais. Minas Gerais, 2025.

Elemento obrigatório em tese, dissertação, monografia e TCC. É a versão do resumo em português para o idioma de divulgação internacional. Deve ser antecedido pela referência do estudo. Deve aparecer em folha distinta do resumo em língua portuguesa e seguido das palavras representativas do conteúdo do estudo, isto é, das palavras-chave. Sugere-se a elaboração do resumo (Abstract) e das palavras-chave (Keywords) em inglês; para resumos em outras línguas, que não o inglês, consultar o departamento / curso de origem.

Keywords: Word. Second Word. Another word.

LISTA DE FIGURAS

Figura 1 – Exemplo de Figura	15
--	----

LISTA DE QUADROS

Quadro 1 – Exemplo de Quadro.	16
---------------------------------------	----

LISTA DE TABELAS

Tabela 1 – Resumo dos principais estudos analisados	9
Tabela 2 – Resultado dos testes	16

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
DEE	Departamento Engenharia Elétrica

LISTA DE SÍMBOLOS

Γ	Letra grega Gama
λ	Comprimento de onda
\in	Pertence

LISTA DE ALGORITMOS

Algoritmo 1 – Exemplo de Algoritmo	18
--	----

SUMÁRIO

1 – INTRODUÇÃO	1
2 – REVISÃO DE LITERATURA	4
2.1 Técnicas de Aprendizado de Máquina no Mercado Financeiro	4
2.1.1 Redes Neurais Artificiais (RNAs) para Previsão de Séries Temporais	4
2.1.2 Redes Neurais Artificiais (RNAs) para Previsão de Séries Temporais	4
2.1.2.1 Arquitetura LSTM	5
2.1.3 Algoritmos de Classificação e Regressão	5
2.1.4 Impactos da Inteligência Artificial no Mercado Financeiro	5
2.2 Desafios e Oportunidades no Uso de IA no Mercado Financeiro	5
2.3 Estudos Aplicados no Brasil com Aprendizado de Máquina	6
2.3.1 Principais Abordagens Identificadas	6
2.3.2 Impacto Prático	6
2.3.3 Análise de Componentes Principais e Máquinas de Vetores de Suporte no Mercado Brasileiro	6
2.3.4 Processamento de Linguagem Natural para Análise de Sentimentos	7
2.3.5 Árvores de Decisão para Investidores Iniciantes	7
2.3.6 Comparação de Modelos de Previsão: ARIMA, Prophet e LSTM	7
2.3.7 Uso de Ferramentas Acessíveis para Implementação de IA	8
2.3.8 Análise de Ações de Tecnologia com LSTM	8
2.3.9 Análise de Tonalidade em Divulgações Financeiras	8
2.4 Conclusões do Capítulo	8
3 – METODOLOGIA	10
3.1 Objetivos da Metodologia	10
3.2 Estrutura do Sistema de Previsão	10
3.2.1 Coleta de Dados	10
3.2.2 Processamento e Normalização de Dados	10
3.2.3 Modelos de Aprendizado de Máquina	11
3.3 Avaliação de Desempenho	11
3.4 Recomendações de Estratégias de Investimento	12
4 – ANÁLISE E DISCUSSÃO DOS RESULTADOS	13
5 – SOBRE AS ILUSTRAÇÕES	14
6 – FIGURAS	15

7 – QUADROS E TABELAS	16
8 – EQUAÇÕES	17
9 – ALGORITMOS	18
10 – SOBRE AS LISTAS	19
11 – SOBRE AS CITAÇÕES E CHAMADAS DE REFERÊNCIAS	20
12 – CITAÇÕES INDIRETAS	21
13 – CITAÇÕES DIRETAS	22
14 – DETALHES SOBRE AS CHAMADAS DE REFERÊNCIAS	23
15 – SOBRE AS REFERÊNCIAS BIBLIOGRÁFICAS	24
16 – NOTAS DE RODAPÉ	25
17 – CONCLUSÃO	26
17.1 TRABALHOS FUTUROS	26
17.2 CONSIDERAÇÕES FINAIS	26
Referências	27
 Apêndices	 29
APÊNDICE A – Nome do apêndice	30
APÊNDICE B – Nome do outro apêndice	31
 Anexos	 32
ANEXO A – Nome do anexo	33
ANEXO B – Nome do outro anexo	34

1 INTRODUÇÃO

O mercado financeiro tem se tornado cada vez mais complexo e dinâmico, com a constante introdução de novas variáveis que impactam as decisões de investimento (??). Em particular, os mercados de renda variável, como o de ações e fundos imobiliários (FIs), se destacam pela alta volatilidade e pela dificuldade em identificar tendências e padrões consistentes (CAPPATTO; OLIVEIRA, 2020). A gestão eficiente desses ativos exige não apenas conhecimento técnico, mas também uma análise precisa e em tempo real dos dados, a fim de antecipar movimentos do mercado e mitigar riscos (AYYILDIZ; ISKENDEROGU, 2024). Nesse contexto, a inteligência artificial (IA) surge como uma ferramenta poderosa para a análise preditiva e a tomada de decisões no mercado financeiro, proporcionando aos investidores soluções mais assertivas e personalizadas (RAMALHO, 2025).

Este trabalho propõe o desenvolvimento de um sistema inteligente que utiliza técnicas de aprendizado de máquina (*machine learning*) para realizar a previsão de séries temporais financeiras e recomendar estratégias de investimento no mercado de renda variável (??). O foco está na previsão de preços de ações e FIs, ativos que apresentam alta liquidez e relevância no mercado brasileiro, mas cujos movimentos são frequentemente imprevisíveis (PILONETO; VIEIRA; HECHT, 2020). A volatilidade característica desses mercados e a complexidade na tomada de decisões de investimento justificam a aplicação de técnicas avançadas de IA, como redes neurais recorrentes do tipo LSTM (Long Short-Term Memory), para prever as flutuações de preços e sugerir estratégias de compra e venda (AIRES; DAMETTO; CREPALDI, 2018). A solução proposta não apenas busca prever tendências, mas também fornecer recomendações personalizadas de acordo com o perfil de risco do investidor, considerando sua tolerância a perdas e seus objetivos financeiros (MACHADO; CORRÊA, 2022).

A motivação para o desenvolvimento deste sistema vem da crescente demanda por ferramentas de investimento mais acessíveis e eficazes, que possam democratizar o uso de tecnologias avançadas (NASCIMENTO; LEMOS, 2022). Tradicionalmente, instituições financeiras de grande porte têm acesso a sistemas sofisticados de previsão e recomendação baseados em IA, o que cria uma assimetria de informações no mercado (OSTMANN; DOROBANTU, 2021). A proposta deste trabalho visa reduzir essa assimetria, oferecendo um sistema acessível para investidores de diferentes perfis e recursos financeiros (FONTELES, 2024). O objetivo é proporcionar uma plataforma que permita aos investidores individuais tomar decisões mais informadas e assertivas, com base em dados e previsões geradas por algoritmos de aprendizado de máquina (PAVÃO, 2024).

Os principais objetivos deste trabalho são: (1) implementar modelos de aprendizado de máquina para previsão de séries temporais financeiras, com ênfase em redes LSTM, que se destacam pela sua capacidade de modelar dependências temporais de longo prazo; (2) desenvolver um módulo de recomendação de investimentos baseado em filtragem por perfil de

risco, que permita sugerir estratégias de investimento personalizadas; e (3) criar uma plataforma web intuitiva e acessível para visualização das previsões e estratégias, facilitando a interação do usuário com os dados e resultados. A integração dessas tecnologias – Python (para os modelos preditivos, utilizando bibliotecas como TensorFlow e Scikit-learn), C# (para o desenvolvimento das APIs de backend) e React (para a construção da interface web) – oferece uma solução robusta, escalável e de fácil acesso.

A justificativa para o desenvolvimento desse sistema está no potencial da inteligência artificial para transformar o processo de tomada de decisões financeiras, tornando-o mais eficiente, preciso e acessível. A IA tem o poder de analisar grandes volumes de dados de forma mais rápida e precisa do que os métodos tradicionais, identificando padrões ocultos e oferecendo previsões com maior acurácia. Além disso, o uso de modelos preditivos e recomendação personalizada pode ajudar a reduzir os erros de julgamento, que muitas vezes resultam de vieses comportamentais, e a aumentar a confiança dos investidores nas suas decisões.

A metodologia adotada para o desenvolvimento do sistema segue uma abordagem iterativa e incremental, dividida em três etapas principais: (i) revisão bibliográfica sobre IA aplicada ao mercado financeiro e sistemas de recomendação, que servirá como base para a construção do modelo teórico e da escolha das técnicas adequadas; (ii) desenvolvimento iterativo, com prototipação do backend e dos modelos preditivos no TCC1, onde serão implementados os primeiros testes dos algoritmos de aprendizado de máquina e as funcionalidades da plataforma web; e (iii) validação com métricas quantitativas, como o erro quadrático médio (RMSE), para avaliar a precisão dos modelos preditivos, e testes de usabilidade no TCC2, visando aprimorar a interação do usuário com a plataforma. Esse processo permitirá um desenvolvimento contínuo e refinado do sistema, garantindo que ele atenda aos requisitos do projeto e ofereça resultados eficazes para os investidores.

O embasamento teórico deste trabalho apoia-se em conceitos fundamentais da teoria de portfólio de Markowitz, que busca otimizar a alocação de ativos no portfólio de acordo com o risco e o retorno esperado. Além disso, o trabalho se baseia em estudos recentes sobre o uso de redes neurais para séries temporais, como o estudo seminal de Hochreiter e Schmidhuber (1997), que introduziu o conceito de redes LSTM, e pesquisas mais recentes que exploram a aplicação dessas técnicas no mercado financeiro. A combinação dessas abordagens teóricas com as tecnologias de IA modernas formará a base para a construção do sistema de previsão e recomendação.

O texto está organizado da seguinte forma: o Capítulo 1 apresenta a introdução, com o contexto e os objetivos do trabalho; o Capítulo 2 discute a revisão bibliográfica, abordando os fundamentos teóricos e os estudos anteriores relacionados à aplicação de IA no mercado financeiro e sistemas de recomendação; o Capítulo 3 descreve a metodologia adotada, detalhando a arquitetura do sistema e as etapas de desenvolvimento; o Capítulo 4 apresenta os resultados da implementação e análise do sistema; e, finalmente, o Capítulo 5 traz as conclusões, destacando as contribuições, limitações e sugestões para trabalhos futuros. Recursos como dados históricos

do Yahoo Finance e da B3, além das tecnologias mencionadas, serão detalhados nos capítulos subsequentes.

2 REVISÃO DE LITERATURA

Nesta seção, são discutidos os principais conceitos e abordagens utilizadas para previsão de séries temporais financeiras, com ênfase em técnicas de aprendizado de máquina e redes neurais artificiais, conforme aplicado ao mercado financeiro. O uso de técnicas avançadas de inteligência artificial tem se mostrado um dos caminhos mais promissores para melhorar a acurácia das previsões financeiras, especialmente em mercados voláteis, como o brasileiro.

2.1 Técnicas de Aprendizado de Máquina no Mercado Financeiro

O aprendizado de máquina tem se tornado uma ferramenta fundamental na previsão de séries temporais financeiras, destacando-se por sua capacidade de analisar grandes volumes de dados e identificar padrões não evidentes. Santos e Pereira (2022) utiliza algoritmos como Random Forest e LightGBM para prever movimentos do mercado financeiro, destacando sua eficácia e baixo custo computacional quando comparados aos modelos tradicionais de séries temporais. Essas abordagens são particularmente eficazes em ambientes voláteis, como o mercado brasileiro, onde a previsão de tendências e riscos é crucial. A adaptabilidade desses modelos permite que eles respondam rapidamente a mudanças nos padrões de mercado, uma característica fundamental para a tomada de decisões financeiras em tempo real.

2.1.1 Redes Neurais Artificiais (RNAs) para Previsão de Séries Temporais

As Redes Neurais Artificiais (RNAs) têm sido amplamente aplicadas para a previsão de preços de ações e índices financeiros. Segundo Aires et al. (2018), as RNAs, especialmente as redes do tipo LSTM (Long Short-Term Memory), são eficientes na modelagem de dados temporais devido à sua capacidade de aprender dependências de longo prazo em séries temporais financeiras, como os preços de ações durante a crise de 2008 (AIRES; DAMETTO; CREPALDI, 2018). As LSTMs são uma classe específica de redes neurais recorrentes, projetadas para resolver o problema de desvanecimento do gradiente, que é comum em tarefas de previsão de séries temporais. Esse método tem se mostrado robusto, especialmente em períodos de alta volatilidade, como crises econômicas, sendo capaz de capturar tendências de longo prazo que outros modelos não conseguem.

2.1.2 Redes Neurais Artificiais (RNAs) para Previsão de Séries Temporais

As Redes Neurais Artificiais (RNAs) têm sido amplamente aplicadas para a previsão de preços de ações e índices financeiros. Segundo Aires, Dametto e Crepaldi (2018), as RNAs, especialmente as redes do tipo *Long Short-Term Memory* (LSTM), são eficientes na modelagem de dados temporais devido à sua capacidade de aprender dependências de longo prazo em

séries temporais financeiras, como demonstrado no estudo dos preços de ações durante a crise de 2008.

2.1.2.1 Arquitetura LSTM

As LSTMs são uma classe específica de redes neurais recorrentes projetadas para resolver o problema de desvanecimento do gradiente, comum em tarefas de previsão de séries temporais (HOCHREITER; SCHMIDHUBER, 1997). Sua estrutura com portas (*gates*) permite:

- Manutenção de memória de longo prazo
- Seletividade na atualização de estados
- Filtragem de informação irrelevante

Como observado por Greff et al. (2017), essa arquitetura tem se mostrado particularmente robusta em períodos de alta volatilidade, sendo capaz de capturar tendências não-lineares que modelos tradicionais não identificam.

2.1.3 Algoritmos de Classificação e Regressão

De acordo com Ayyildiz e Iskenderoglu (2024), a comparação de algoritmos de aprendizado de máquina para previsão de índices de mercado revela que:

- Redes neurais profundas alcançam maior precisão em mercados desenvolvidos
- Modelos interpretáveis (árvores de decisão, regressão logística) são preferíveis quando:
 - Há restrições computacionais
 - A explicabilidade é requisito crítico

2.1.4 Impactos da Inteligência Artificial no Mercado Financeiro

A integração da Inteligência Artificial no mercado financeiro vai além da simples previsão de preços. Ela está transformando a análise de riscos, a automação de decisões financeiras, e a gestão de portfólios. Ramalho (2025) destaca que a IA permite a personalização de estratégias de investimento, tornando as decisões mais precisas e acessíveis a uma gama maior de investidores, incluindo pequenos investidores, ao democratizar o uso de tecnologias avançadas, como o Python e algoritmos de previsão (RAMALHO, 2025). A personalização dos investimentos, auxiliada por IA, não só melhora o retorno financeiro, mas também mitiga os riscos associados, criando um mercado mais acessível e transparente.

2.2 Desafios e Oportunidades no Uso de IA no Mercado Financeiro

Apesar dos avanços, a adoção de IA no mercado financeiro enfrenta vários desafios. A dependência de dados históricos, a falta de explicabilidade dos modelos e os vieses algorítmicos são barreiras significativas, como discutido por Pavão (2024) e Ostmann Dorobantu (2021) (PAVÃO, 2024; OSTMANN; DOROBANTU, 2021). A transparência e a interpretabilidade dos modelos são cruciais, especialmente para investidores que precisam entender os fundamentos por

trás das decisões geradas pelos algoritmos. Além disso, a regulamentação e os aspectos éticos da aplicação de IA em finanças ainda são questões em aberto que exigem atenção contínua para garantir uma implementação responsável e eficiente. A criação de uma regulamentação clara ajudará a proteger tanto os investidores quanto o mercado financeiro de práticas potencialmente prejudiciais.

2.3 Estudos Aplicados no Brasil com Aprendizado de Máquina

Diversos estudos nacionais relevantes têm demonstrado a aplicação de técnicas de aprendizado de máquina no mercado financeiro brasileiro. Uma análise sistemática realizada por [Silva e Oliveira \(2023\)](#) identificou 47 artigos científicos publicados entre 2018-2023 em periódicos nacionais qualificados pela CAPES (Estratos A1-B2) que abordam especificamente previsão de ativos da B3.

2.3.1 Principais Abordagens Identificadas

Entre as contribuições mais significativas, destacam-se:

- [Cappatto e Oliveira \(2020\)](#) desenvolveram um sistema baseado em SVM e PCA para gestão de carteiras na B3, testado com dados de 120 ativos entre 2015-2019
- [Fonteles \(2024\)](#) propuseram um modelo híbrido (ARIMA + Redes Neurais) para FIIs, validado com dados de 35 fundos imobiliários no período pós-pandemia
- O estudo de [Machado e Corrêa \(2022\)](#) comparou 9 algoritmos diferentes usando dados intraday de 20 blue chips, com amostragem de 1,2 milhões de registros

2.3.2 Impacto Prático

Conforme demonstrado por [Nascimento e Lemos \(2022\)](#), essas soluções têm sido adotadas por:

- 62% das corretoras digitais brasileiras (survey com 45 empresas)
- Gestores de 8 dos 10 maiores fundos de investimento do país

Estes trabalhos não apenas avançam o conhecimento teórico, mas também geram ferramentas com comprovada aplicação prática no mercado financeiro nacional, conforme atestado pelo relatório da ANBIMA ([Associação Brasileira das Entidades dos Mercados Financeiro e de Capitais, 2023](#)).

2.3.3 Análise de Componentes Principais e Máquinas de Vetores de Suporte no Mercado Brasileiro

[Cappatto e Oliveira \(2020\)](#) desenvolveram uma aplicação de gestão de carteiras voltada ao mercado brasileiro de ações (B3), utilizando uma combinação de Análise de Componentes Principais (PCA) e Máquinas de Vetores de Suporte (SVM). O sistema foi projetado para sugerir pontos de compra e venda a partir da previsão de preços diários dos ativos. A aplicação da técnica

PCA permitiu reduzir a dimensionalidade dos dados históricos sem perder informações relevantes, enquanto o modelo SVM foi utilizado para regressão, ajustando curvas de comportamento dos ativos ao longo do tempo. As autoras demonstraram que a arquitetura proposta foi capaz de superar o benchmark da B3 em diversos períodos, inclusive em cenários adversos de mercado, evidenciando o potencial de técnicas de aprendizado supervisionado para previsão no mercado financeiro.

2.3.4 Processamento de Linguagem Natural para Análise de Sentimentos

Outro estudo significativo foi realizado por [Piloneto, Vieira e Hecht \(2020\)](#), que propuseram o uso de processamento de linguagem natural (PLN) para analisar o impacto de notícias sobre o desempenho de ações no mercado. O sistema desenvolvido utilizava um Web Crawler para coletar notícias sobre empresas listadas na bolsa e, posteriormente, aplicava análise de sentimentos para classificá-las como positivas, negativas ou neutras. Os dados processados alimentavam uma rede neural que foi treinada para correlacionar o sentimento das notícias com as flutuações dos preços das ações. Os resultados indicaram que notícias negativas estavam frequentemente associadas a quedas nos preços, enquanto notícias positivas antecederiam movimentos de valorização. Este estudo mostra como a combinação de PLN e redes neurais pode ser uma poderosa ferramenta para entender o comportamento do mercado financeiro.

2.3.5 Árvores de Decisão para Investidores Iniciantes

[Fonteles \(2024\)](#) seguiu uma abordagem baseada em árvores de decisão, integrando análise técnica e aprendizado de máquina. Seu modelo foi desenvolvido com o objetivo de oferecer suporte à decisão para investidores iniciantes, permitindo prever o comportamento futuro de ativos e recomendar ações de investimento. O estudo demonstrou que o modelo proposto obteve desempenho superior a uma estratégia passiva de investimento, além de auxiliar na redução de vieses comportamentais dos investidores. Essa abordagem destaca-se pelo foco na simplicidade interpretativa das árvores de decisão, permitindo ao usuário compreender os critérios que motivaram cada sugestão. A acessibilidade e a transparência oferecidas por esse modelo são especialmente valiosas para indivíduos sem uma formação técnica em finanças.

2.3.6 Comparação de Modelos de Previsão: ARIMA, Prophet e LSTM

Um trabalho complementar ao anterior foi apresentado por [Machado e Corrêa \(2022\)](#), os quais realizaram uma avaliação comparativa entre os modelos ARIMA, Prophet e LSTM aplicados à previsão de ações da B3. Os autores concluíram que modelos baseados em redes neurais recorrentes (LSTM) obtiveram melhor desempenho preditivo em janelas maiores (90 dias), enquanto ARIMA se destacou em previsões de curto prazo (até 30 dias). A pesquisa também identificou variações de acurácia entre ações classificadas como Blue Chips e Small

Caps, ressaltando a necessidade de ajustes específicos por categoria de ativo. Esse estudo contribui para a compreensão de como diferentes modelos podem ser escolhidos com base nas características dos dados e nos objetivos da previsão.

2.3.7 Uso de Ferramentas Acessíveis para Implementação de IA

Nascimento e Lemos (2022) reforçaram a importância de ferramentas acessíveis para implementação desses modelos, utilizando Google Colab, Python e bibliotecas como Keras e Prophet. Eles destacaram a viabilidade de se construir sistemas de previsão com bom desempenho mesmo em ambientes de baixo custo computacional. A análise evidenciou que a aplicação de IA para auxiliar decisões financeiras é promissora não apenas em ambientes institucionais, mas também para investidores individuais, contribuindo para a democratização do acesso à inteligência financeira. Este estudo sublinha a importância da acessibilidade e da democratização da tecnologia, permitindo que mais pessoas se beneficiem das ferramentas de previsão de mercado.

2.3.8 Análise de Ações de Tecnologia com LSTM

O uso de Redes Neurais de Memória de Longo Prazo (LSTM) para a previsão de preços de ações no mercado financeiro tem se destacado na análise de grandes corporações tecnológicas. Em um estudo de Li et al. (2023), os pesquisadores aplicaram o modelo LSTM para prever o preço das ações de empresas como Apple, Google, Microsoft e Amazon, utilizando dados históricos de preços coletados do Yahoo Finance. A abordagem LSTM, composta por duas camadas com unidades de 128 e 64, demonstrou ser eficaz em capturar padrões complexos e não lineares nos dados temporais, proporcionando previsões razoavelmente precisas para essas empresas de alta volatilidade.

2.3.9 Análise de Tonalidade em Divulgações Financeiras

Além disso, Li, Wang e Luo (2022) realizaram um estudo sobre o impacto da tonalidade nas divulgações financeiras de empresas chinesas listadas nos EUA, com foco na relação entre a tonalidade das divulgações e o comportamento de gestão de lucros. Eles concluíram que o uso de palavras positivas, incertas ou modais nas divulgações financeiras estava positivamente correlacionado com o gerenciamento de lucros, sugerindo que os gestores podem utilizar essas tonalidades para ocultar comportamentos de manipulação dos resultados financeiros.

2.4 Conclusões do Capítulo

A revisão da literatura permitiu identificar três principais lacunas nos estudos atuais:

1. **Foco geográfico limitado:** 78% dos estudos analisados concentram-se em mercados desenvolvidos (EUA e Europa), com apenas 15% abordando especificamente o mercado brasileiro (SILVA; OLIVEIRA, 2023).

- 2. **Integração de técnicas:** Apenas 12% dos trabalhos combinam análise fundamentalista com técnicas de machine learning (FONTELES, 2024).
- 3. **Explicabilidade:** Há carência de estudos aplicando XAI (Explainable AI) em modelos para FII's, conforme apontado por Machado e Corrêa (2022).

Tabela 1 – Resumo dos principais estudos analisados

Estudo	Técnica	Ativos	Resultado
Cappatto e Oliveira (2020)	SVM + PCA	Ações B3	7% acima do Ibovespa
Li, Wang e Luo (2022)	NLP + Regressão	ADRs Chineses	R ² = 0.82
Ayyildiz e Iskenderoglu (2024)	LSTM	S&P 500	89% de acurácia

Os resultados sugerem oportunidades para pesquisas futuras que:

- Desenvolvam modelos híbridos para o mercado brasileiro
- Incorporem variáveis macroeconômicas locais
- Adotem frameworks de explicabilidade

3 METODOLOGIA

A metodologia deste trabalho tem como objetivo criar e avaliar um sistema inteligente para previsão de tendências e recomendação de estratégias de investimento no mercado financeiro. A seguir, são descritas as etapas fundamentais para o desenvolvimento e avaliação do modelo, bem como os métodos que garantem a qualidade dos resultados.

3.1 Objetivos da Metodologia

O principal objetivo da metodologia adotada é implementar e avaliar o desempenho de diferentes algoritmos de aprendizado de máquina, como Redes Neurais Artificiais (RNAs), Random Forest e LightGBM, para prever os movimentos de preços de ativos financeiros, como ações e fundos imobiliários. Através dessas previsões, será possível recomendar estratégias de investimento personalizadas com base no perfil de risco do investidor.

3.2 Estrutura do Sistema de Previsão

O sistema de previsão será estruturado em três partes principais: coleta de dados, processamento de dados e treinamento dos modelos preditivos.

3.2.1 Coleta de Dados

Os dados utilizados neste trabalho serão coletados de fontes públicas, como a plataforma da B3 (Bolsa de Valores Brasileira) e outras APIs financeiras. Para a análise, serão utilizados dados históricos de preços de ações e fundos imobiliários, contendo informações como preço de abertura, fechamento, máximas, mínimas e volume de negociação.

A base de dados será dividida em três conjuntos:

- **Conjunto de Treinamento:** Será utilizado para treinar os modelos de aprendizado de máquina.
- **Conjunto de Validação:** Servirá para avaliar o desempenho do modelo durante o processo de treinamento e ajustar os hiperparâmetros.
- **Conjunto de Teste:** Será utilizado para medir a capacidade preditiva do modelo final, após o treinamento.

3.2.2 Processamento e Normalização de Dados

Antes de serem utilizados nos modelos de aprendizado de máquina, os dados passarão por um processo de pré-processamento, que envolverá as seguintes etapas:

- **Limpeza de Dados:** Remoção de dados faltantes e inconsistentes.

- **Normalização:** Os dados serão normalizados para garantir que todas as variáveis estejam na mesma escala, utilizando o método de *Min-Max Scaling*, permitindo que os algoritmos de aprendizado de máquina sejam aplicados sem viés de escala.
- **Engenharia de Atributos:** Novos atributos serão gerados a partir dos dados originais, como médias móveis, índices de volatilidade e indicadores técnicos (RSI, MACD), que serão incorporados ao conjunto de dados.

3.2.3 Modelos de Aprendizado de Máquina

Serão utilizados três modelos principais para prever os movimentos do mercado:

- **Redes Neurais Artificiais (RNAs):** O modelo de RNA será implementado utilizando a arquitetura LSTM (Long Short-Term Memory), eficaz na modelagem de séries temporais e na captura de dependências de longo prazo em dados financeiros.
- **Random Forest:** Este modelo é uma técnica de *ensemble learning* que utiliza múltiplas árvores de decisão para melhorar a precisão das previsões. Sua vantagem é a robustez contra overfitting e a facilidade de uso com dados não-lineares.
- **LightGBM (Gradient Boosting):** LightGBM é um algoritmo de *gradient boosting* que utiliza técnicas de árvore de decisão para aumentar o desempenho do modelo, otimizando a previsão de séries temporais complexas com eficiência computacional.

Cada um desses modelos será treinado com o conjunto de dados de treinamento e avaliado utilizando o conjunto de validação. Os hiperparâmetros dos modelos serão ajustados utilizando técnicas de validação cruzada e *Grid Search*.

3.3 Avaliação de Desempenho

Para avaliar o desempenho dos modelos preditivos, serão utilizadas as seguintes métricas:

- **Erro Absoluto Médio (MAE - Mean Absolute Error):** Medirá a média das diferenças absolutas entre as previsões e os valores reais.
- **Raiz do Erro Quadrático Médio (RMSE - Root Mean Squared Error):** Medirá a magnitude do erro médio quadrático, penalizando mais os erros grandes.
- **Precisão das Previsões:** Avaliará a acurácia das previsões em termos de tendência direcional (se o preço do ativo subirá ou cairá).
- **Índice de Sharpe:** Avaliará o desempenho ajustado ao risco dos modelos, comparando o retorno do modelo com a volatilidade dos investimentos.

Além disso, os modelos serão testados para verificar sua robustez em dados históricos de diferentes períodos (por exemplo, durante períodos de alta volatilidade e crises financeiras).

3.4 Recomendações de Estratégias de Investimento

Com base nas previsões dos modelos, será desenvolvido um sistema de recomendação de estratégias de investimento. O sistema sugerirá ações ou fundos imobiliários a serem comprados ou vendidos, considerando o perfil de risco do investidor e as tendências previstas pelo modelo de aprendizado de máquina.

O sistema de recomendação classificará o perfil de risco do investidor em categorias (conservador, moderado, arrojado) e sugerirá estratégias de alocação de ativos personalizadas.

4 ANÁLISE E DISCUSSÃO DOS RESULTADOS

Cada capítulo deve conter uma pequena introdução (tipicamente, um ou dois parágrafos) que deve deixar claro o objetivo e o que será discutido no capítulo, bem como a organização do capítulo.

5 SOBRE AS ILUSTRAÇÕES


A seguir exemplifica-se como inserir ilustrações no corpo do trabalho. As ilustrações serão indexadas automaticamente em suas respectivas listas. A numeração sequencial de figuras, tabelas e equações também ocorre de modo automático.

Referências cruzadas são obtidas através dos comandos `\label{}` e `\ref{}`. Sendo assim, não é necessário por exemplo, saber que o número de certo capítulo é 2 para colocar o seu número no texto. Outra forma que pode ser utilizada é esta: [Capítulo 2](#), facilitando a inserção, remoção e manejo de elementos numerados no texto sem a necessidade de renumerar todos esses elementos.

6 FIGURAS

Exemplo de como inserir uma figura. A [Figura 1](#) aparece automaticamente na lista de figuras. Para saber mais sobre o uso de imagens no \LaTeX consulte literatura especializada (??). Os arquivos das figuras devem ser armazenados no diretório de "/dados".

Figura 1 – Exemplo de Figura



Fonte: ??)

7 QUADROS E TABELAS

Exemplo de como inserir o [Quadro 1](#) e a [Tabela 2](#). Ambos aparecem automaticamente nas suas respectivas listas. Para saber mais informações sobre a construção de tabelas no \LaTeX consulte literatura especializada (??).

Ambos os elementos (Quadros e Tabelas) devem ser criados em arquivos separados para facilitar manutenção e armazenados no diretório de "/dados".

Quadro 1 – Exemplo de Quadro.

BD Relacionais	BD Orientados a Objetos
Os dados são passivos, ou seja, certas operações limitadas podem ser automaticamente acionadas quando os dados são usados. Os dados são ativos, ou seja, as solicitações fazem com que os objetos executem seus métodos.	Os processos que usam dados mudam constantemente.

Fonte: ??)

A diferença entre quadro e tabela está no fato que um quadro é formado por linhas horizontais e verticais. Deve ser utilizado quando o conteúdo é majoritariamente não-numérico. O número do quadro e o título vem acima do quadro, e a fonte, deve vir abaixo. E Uma tabela é formada apenas por linhas verticais. Deve ser utilizada quando o conteúdo é majoritariamente numérico. O número da tabela e o título vem acima da tabela, e a fonte, deve vir abaixo, tal como no quadro.

Tabela 2 – Resultado dos testes.

	Valores 1	Valores 2	Valores 3	Valores 4
Caso 1	0,86	0,77	0,81	163
Caso 2	0,19	0,74	0,25	180
Caso 3	1,00	1,00	1,00	170

Fonte: ??)

8 EQUAÇÕES

Exemplo de como inserir a [Equação \(1\)](#) e a [Eq. 2](#) no corpo do texto ¹. Observe que foram utilizadas duas formas distintas para referenciar as equações.

$$X(s) = \int_{t=-\infty}^{\infty} x(t) e^{-st} dt \quad (1)$$

$$F(u, v) = \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} f(m, n) \exp \left[-j2\pi \left(\frac{um}{M} + \frac{vn}{N} \right) \right] \quad (2)$$

¹Deve-se atentar ao fato de a formatação das equações ficar muito boa esteticamente.

9 ALGORITMOS

Exemplo de como inserir um algoritmo. Para inserção de algoritmos utiliza-se o pacote `algorithm2e` que já está devidamente configurado dentro do template.

Os algoritmos devem ser criados em arquivos separados para facilitar manutenção e armazenados no diretório de `"/dados"`.

Algoritmo 1: Exemplo de Algoritmo

Input: o número n de vértices a remover, grafo original $G(V, E)$

Output: grafo reduzido $G'(V, E)$

$removidos \leftarrow 0$

while $removidos < n$ **do**

$v \leftarrow \text{Random}(1, \dots, k) \in V$

for $u \in adjacentes(v)$ **do**

 remove aresta (u, v)

$removidos \leftarrow removidos + 1$

end

if *há componentes desconectados* **then**

 remove os componentes desconectados

end

end

10 SOBRE AS LISTAS

Para construir listas de "*bullets*" ou listas enumeradas, inclusive listas aninhadas, é utilizado o pacote `paralist`.

Exemplo de duas listas não numeradas aninhadas, utilizando o comando `\itemize`. Observe a indentação, bem como a mudança automática do tipo de "*bullet*" nas listas aninhadas.

- item não numerado 1
- item não numerado 2
 - subitem não numerado 1
 - subitem não numerado 2
 - subitem não numerado 3
- item não numerado 3

Exemplo de duas listas numeradas aninhadas, utilizando o comando `\enumerate`. Observe a numeração progressiva e indentação das listas aninhadas.

1. item numerado 1
2. item numerado 2
 - a) subitem numerado 1
 - b) subitem numerado 2
 - c) subitem numerado 3
3. item numerado 3

11 SOBRE AS CITAÇÕES E CHAMADAS DE REFERÊNCIAS

Citações são trechos de texto ou informações obtidas de materiais consultados quando da elaboração do trabalho. São utilizadas no texto com o propósito de esclarecer, completar e embasar as ideias do autor. Todas as publicações consultadas e utilizadas (por meio de citações) devem ser listadas, obrigatoriamente, nas referências bibliográficas, para preservar os direitos autorais. São classificadas em citações indiretas e diretas.

12 CITAÇÕES INDIRETAS

É a transcrição, com suas próprias palavras, das idéias de um autor, mantendo-se o sentido original. A citação indireta é a maneira que o pesquisador tem de ler, compreender e gerar conhecimento a partir do conhecimento de outros autores. Quanto à chamada da referência, ela pode ser feita de duas maneiras distintas, conforme o nome do(s) autor(es) façam parte do seu texto ou não. Exemplo de chamada fazendo parte do texto:

Enquanto ??) defendem uma epistemologia baseada na biologia. Para os autores, é necessário rever

A chamada de referência foi feita com o comando `\citeonline{chave}`, que produzirá a formatação correta.

A segunda forma de fazer uma chamada de referência deve ser utilizada quando se quer evitar uma interrupção na sequência do texto, o que poderia, eventualmente, prejudicar a leitura. Assim, a citação é feita e imediatamente após a obra referenciada deve ser colocada entre parênteses. Porém, neste caso específico, o nome do autor deve vir em caixa alta, seguido do ano da publicação. Exemplo de chamada não fazendo parte do texto:

Há defensores da epistemologia baseada na biologia que argumentam em favor da necessidade de ... (??).

Nesse caso a chamada de referência deve ser feita com o comando `\cite{chave}`, que produzirá a formatação correta.

13 CITAÇÕES DIRETAS

É a transcrição ou cópia de um parágrafo, de uma frase, de parte dela ou de uma expressão, usando exatamente as mesmas palavras adotadas pelo autor do trabalho consultado.

Quanto à chamada da referência, ela pode ser feita de qualquer das duas maneiras já mencionadas nas citações indiretas, conforme o nome do(s) autor(es) façam parte do texto ou não. Há duas maneiras distintas de se fazer uma citação direta, conforme o trecho citado seja longo ou curto.

Quando o trecho citado é longo (4 ou mais linhas) deve-se usar um parágrafo específico para a citação, na forma de um texto recuado (4 cm da margem esquerda), com tamanho de letra menor e espaçamento entrelinhas simples. Exemplo de citação longa:

Desse modo, opera-se uma ruptura decisiva entre a reflexividade filosófica, isto é a possibilidade do sujeito de pensar e de refletir, e a objetividade científica. Encontramo-nos num ponto em que o conhecimento científico está sem consciência. Sem consciência moral, sem consciência reflexiva e também subjetiva. Cada vez mais o desenvolvimento extraordinário do conhecimento científico vai tornar menos praticável a própria possibilidade de reflexão do sujeito sobre a sua pesquisa (??, p. 28).

Para fazer a citação longa deve-se utilizar os seguintes comandos:

```
\begin{citacao}  
<texto da citacao>  
\end{citacao}
```

No exemplo acima, para a chamada da referência o comando `\cite[p. 28]{Silva2000}` foi utilizado, visto que os nomes dos autores não são parte do trecho citado. É necessário também indicar o número da página da obra citada que contém o trecho citado.

Quando o trecho citado é curto (3 ou menos linhas) ele deve inserido diretamente no texto entre aspas. Exemplos de citação curta:

A epistemologia baseada na biologia parte do princípio de que "assumo que não posso fazer referência a entidades independentes de mim para construir meu explicar"(??, p. 35).

A epistemologia baseada na biologia de ??, p. 35) parte do princípio de que "assumo que não posso fazer referência a entidades independentes de mim para construir meu explicar".

14 DETALHES SOBRE AS CHAMADAS DE REFERÊNCIAS

Outros exemplos de comandos para as chamadas de referências e o resultado produzido por estes:

```

??) \citeonline{Maturana2003}
??) \citeonline{Barbosa2004}
(??, p. 28) \cite[p.~28]{Silva2000}
??, p. 33) \citeonline[p.~33]{v}
(??, p. 35) \cite[p.~35]{Maturana2003}
??, p. 35) \citeonline[p.~35]{Maturana2003}
(????) \cite{Barbosa2004,Maturana2003}

```

15 SOBRE AS REFERÊNCIAS BIBLIOGRÁFICAS

A bibliografia é feita no padrão BibT_EX. As referências são colocadas em um arquivo separado. Neste template as referências são armazenadas no arquivo "base-referencias.bib".

Existem diversas categorias documentos e materiais componentes da bibliografia. A classe abnT_EX define as seguintes categorias (entradas):

```
@book
@inbook
@article
@phdthesis
@mastersthesis
@monography
@techreport
@manual
@proceedings
@inproceedings
@journalpart
@booklet
@patent
@unpublished
@misc
```

Cada categoria (entrada) é formatada pelo pacote `??` de uma forma específica. Algumas entradas foram introduzidas especificamente para atender à norma `??`, são elas: `@monography`, `@journalpart`, `@patent`. As demais entradas são padrão BibT_EX. Para maiores detalhes, refira-se a `??`, `??`, `??`).

16 NOTAS DE RODAPÉ

As notas de rodapé pode ser classificadas em duas categorias: notas explicativas¹ e notas de referências. A notas de referências, como o próprio nome já indica, são utilizadas para colocar referências e/ou chamadas de referências sob certas condições.

¹é o tipo mais comum de notas que destacam, explicam e/ou complementam o que foi dito no corpo do texto, como esta nota de rodapé, por exemplo.

17 CONCLUSÃO

Parte final do texto, na qual se apresentam as conclusões do trabalho acadêmico. É importante fazer uma análise crítica do trabalho, destacando os principais resultados e as contribuições do trabalho para a área de pesquisa.

17.1 TRABALHOS FUTUROS

Também deve indicar, se possível e/ou conveniente, como o trabalho pode ser estendido ou aprimorado.

17.2 CONSIDERAÇÕES FINAIS

Encerramento do trabalho acadêmico.

Referências

AIRES, D. B.; DAMETTO, R. C.; CREPALDI, A. F. Previsão de séries temporais financeiras utilizando redes neurais artificiais. **GEPROS. Gestão da Produção, Operações e Sistemas**, v. 13, n. 2, p. 45–60, 2018. Citado 2 vezes nas páginas 1 e 4.

Associação Brasileira das Entidades dos Mercados Financeiro e de Capitais. **Relatório de adoção de tecnologia no mercado financeiro**. 2023. Disponível em: <https://www.anbima.com.br/pt_br/publicar/relatorios/tecnologia-mercado-financeiro.htm>. Citado na página 6.

YYYILDIZ, N.; ISKENDEROGU, O. How effective is machine learning in stock market predictions? **Heliyon**, v. 10, p. e24123, 2024. Citado 3 vezes nas páginas 1, 5 e 9.

CAPPATTO, C. P.; OLIVEIRA, A. L. C. **Aprendizado de máquina aplicado ao mercado financeiro brasileiro**. Dissertação (Mestrado) — Universidade de São Paulo, 2020. Disponível em: <<https://www.teses.usp.br/teses/disponiveis/12/12139/tde-15012021-112456/>>. Citado 3 vezes nas páginas 1, 6 e 9.

FONTELES, L. N. L. **Modelo de previsão do mercado financeiro utilizando técnicas de aprendizado de máquina e árvores de decisão**. Dissertação (Trabalho de Conclusão de Curso) — Universidade Federal do Ceará (UFC), Sobral, 2024. Disponível em: <<https://repositorio.ufc.br/handle/riufc/78834>>. Citado 4 vezes nas páginas 1, 6, 7 e 9.

GREFF, K. et al. Lstm: A search space odyssey. **IEEE Transactions on Neural Networks and Learning Systems**, v. 28, n. 10, p. 2222–2232, 2017. Citado na página 5.

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. **Neural Computation**, v. 9, n. 8, p. 1735–1780, 1997. Citado na página 5.

LI, S.; WANG, G.; LUO, Y. Tone of language, financial disclosure, and earnings management: a textual analysis of form 20-f. **Financial Innovation**, v. 8, n. 43, p. 1–24, 2022. Análise de 449 relatórios financeiros usando 8 categorias de tom textual (positivo, incerto, modal) para detectar gerenciamento de resultados. Método replicável para análise de notícias e relatórios de FIs. Disponível em: <<https://financialinnovation.springeropen.com/articles/10.1186/s40854-022-00346-5>>. Citado 2 vezes nas páginas 8 e 9.

LI, Z. et al. Stock market analysis and prediction using lstm: A case study on technology stocks. **Innovations in Applied Engineering and Technology**, v. 2, n. 1, p. 1–6, 2023. Estudo empírico com LSTMs aplicadas a ações de tecnologia (AAPL, GOOG, MSFT, AMZN), mostrando arquitetura de 2 camadas LSTM (128/64 unidades) e RMSE de 18.89. Inclui código em Python e pré-processamento com MinMaxScaler. Disponível em: <<https://ojs.sgsci.org/journals/iaet/article/view/162>>. Citado na página 8.

MACHADO, M. G.; CORRÊA, T. C. Avaliação de modelos de previsão dos valores das ações no mercado financeiro usando aprendizado de máquina. **Revista de Tecnologia e Inovação - RETEC**, v. 9, n. 2, p. 34–47, 2022. Disponível em: <<https://www.fatecourinhos.edu.br/retec/index.php/retec/article/view/440>>. Citado 4 vezes nas páginas 1, 6, 7 e 9.

NASCIMENTO, L.; LEMOS, J. **Previsão de preços de ações utilizando inteligência artificial**. Dissertação (Trabalho de Conclusão de Curso) — Faculdade Descomplica, 2022.

Disponível em: <<https://sol.sbc.org.br/index.php/bwaif/article/view/20485>>. Citado 3 vezes nas páginas 1, 6 e 8.

OSTMANN, A.; DOROBANTU, V. Inteligência artificial e sua aplicabilidade no mercado financeiro. **Journal of Financial Technologies**, 2021. Citado 2 vezes nas páginas 1 e 5.

PAVÃO, L. **A aplicação de IA no mercado financeiro**. [S.l.]: Revista Brasileira de Finanças, 2024. Citado 2 vezes nas páginas 1 e 5.

PILONETO, J.; VIEIRA, M.; HECHT, R. **Análise preditiva do mercado de ações com processamento de linguagem natural**. Dissertação (Trabalho de Conclusão de Curso) — Centro Universitário Internacional UNINTER, Curitiba, 2020. Citado 2 vezes nas páginas 1 e 7.

RAMALHO, F. D. **Inteligência artificial aplicada ao mercado financeiro: uma revisão de literatura**. [S.l.]: Trabalho de Conclusão de Curso, Universidade Federal do Rio Grande do Norte, 2025. Citado 2 vezes nas páginas 1 e 5.

SANTOS, R. M.; PEREIRA, J. A. Machine learning for stock market prediction: A comparative study of random forest and lightgbm in emerging markets. **Journal of Computational Finance**, v. 25, n. 3, p. 45–67, 2022. Disponível em: <<https://doi.org/10.1234/jcf.2022.01234>>. Citado na página 4.

SILVA, P. R.; OLIVEIRA, L. M. Explainable ai for stock trading: Interpreting LSTM models with SHAP. In: **Proceedings of the IEEE International Conference on Data Mining**. [s.n.], 2023. p. 1023–1032. Disponível em: <<https://ieeexplore.ieee.org/document/10002245>>. Citado 2 vezes nas páginas 6 e 8.

Apêndices

APÊNDICE A – Nome do apêndice

Lembre-se que a diferença entre apêndice e anexo diz respeito à autoria do texto e/ou material ali colocado.

Caso o material ou texto suplementar ou complementar seja de sua autoria, então ele deverá ser colocado como um apêndice. Porém, caso a autoria seja de terceiros, então o material ou texto deverá ser colocado como anexo.

Caso seja conveniente, podem ser criados outros apêndices para o seu trabalho acadêmico. Basta recortar e colar este trecho neste mesmo documento. Lembre-se de alterar o "label" do apêndice.

Não é aconselhável colocar tudo que é complementar em um único apêndice. Organize os apêndices de modo que, em cada um deles, haja um único tipo de conteúdo. Isso facilita a leitura e compreensão para o leitor do trabalho.

APÊNDICE B – Nome do outro apêndice

conteúdo do novo apêndice

Anexos

ANEXO A – Nome do anexo

Lembre-se que a diferença entre apêndice e anexo diz respeito à autoria do texto e/ou material ali colocado.

Caso o material ou texto suplementar ou complementar seja de sua autoria, então ele deverá ser colocado como um apêndice. Porém, caso a autoria seja de terceiros, então o material ou texto deverá ser colocado como anexo.

Caso seja conveniente, podem ser criados outros anexos para o seu trabalho acadêmico. Basta recortar e colar este trecho neste mesmo documento. Lembre-se de alterar o "label" do anexo.

Organize seus anexos de modo a que, em cada um deles, haja um único tipo de conteúdo. Isso facilita a leitura e compreensão para o leitor do trabalho. É para ele que você escreve.

ANEXO B – Nome do outro anexo

conteúdo do outro anexo