

UNIVERSIDADE FEDERAL DE MINAS GERAIS  
DEE - DEPARTAMENTO DE ENGENHARIA ELÉTRICA  
CURSO DE ENGENHARIA DE SISTEMAS

RAFAEL LIMA CAIRES

**SISTEMA INTELIGENTE PARA ANÁLISE PREDITIVA E  
RECOMENDAÇÃO DE ESTRATÉGIAS PARA O MERCADO DE  
RENDA VARIÁVEL**

TRABALHO DE CONCLUSÃO DE CURSO

MINAS GERAIS  
2025

RAFAEL LIMA CAIRES

**SISTEMA INTELIGENTE PARA ANÁLISE PREDITIVA E  
RECOMENDAÇÃO DE ESTRATÉGIAS PARA O MERCADO DE  
RENDA VARIÁVEL**

Trabalho de Conclusão de Curso apresentado ao Curso de Engenharia de Sistemas da Universidade Federal de Minas Gerais, como requisito parcial para a obtenção do título de bacharel em Engenharia de Sistemas.

Orientadora: Gabriela Nunes Lopes  
Universidade Federal de Minas Gerais

MINAS GERAIS  
2025

Dedico este trabalho aos meus pais, pelo amor incondicional e apoio em todas as fases da minha vida. À minha família, pela paciência e compreensão durante esta jornada. E a todos que acreditaram em mim, mesmo quando eu duvidei.

## **AGRADECIMENTOS**

Agradeço primeiramente à minha orientadora, professora Gabriela Nunes Lopes, pela orientação técnica, paciência e incentivo contínuo ao longo deste trabalho. Sua contribuição foi essencial para o desenvolvimento desta pesquisa.

À Universidade Federal de Minas Gerais (UFMG) e ao curso de Engenharia de Sistemas, pela formação acadêmica sólida e pelo ambiente desafiador e acolhedor.

Aos meus colegas e amigos de curso, pelas discussões, apoio e convivência ao longo da graduação. Em especial àqueles que contribuíram direta ou indiretamente com sugestões, revisões e testes ao longo do projeto.

Aos meus pais e familiares, pelo amor, compreensão e incentivo constante, que foram fundamentais para que eu pudesse chegar até aqui.

*Uma máquina inteligente deve ser capaz de aprender com a experiência. Essa é a essência da inteligência, seja ela humana ou artificial.*

*— Inspirado em Alan Turing*

## RESUMO

CAIRES, Rafael Lima. Sistema Inteligente para Análise Preditiva e Recomendação de Estratégias para o Mercado de Renda Variável. 2025. 27 f. Trabalho de Conclusão de Curso – Curso de Engenharia de Sistemas, Universidade Federal de Minas Gerais. Minas Gerais, 2025.

Este trabalho apresenta o desenvolvimento de um sistema inteligente voltado para análise preditiva e recomendação de estratégias de investimento no mercado de renda variável. Utilizando técnicas de aprendizado de máquina, como redes neurais do tipo LSTM, Random Forest e LightGBM, o sistema busca prever séries temporais de ativos financeiros como ações e fundos imobiliários. Os dados utilizados são coletados de fontes públicas, processados e normalizados para alimentar os modelos preditivos, que são avaliados com métricas como RMSE, MAE e índice de Sharpe. Além da previsão, o sistema incorpora um módulo de recomendação capaz de sugerir alocações de ativos personalizadas, com base no perfil de risco do investidor (conservador, moderado ou arrojado). O projeto também contempla o desenvolvimento de uma plataforma web responsiva e intuitiva, com backend em C e frontend em React, integrada às bibliotecas de IA em Python, permitindo o acesso fácil às previsões e sugestões geradas. A proposta visa democratizar o acesso a tecnologias financeiras avançadas, reduzindo a assimetria de informação no mercado e contribuindo para decisões de investimento mais embasadas e seguras.

**Palavras-chave:** aprendizado de máquina. mercado financeiro. LSTM. recomendação de investimentos. séries temporais.

## ABSTRACT

CAIRES, Rafael Lima. Intelligent System for Predictive Analysis and Strategy Recommendation for the Variable Income Market. 2025. 27 f. Trabalho de Conclusão de Curso – Curso de Engenharia de Sistemas, Universidade Federal de Minas Gerais. Minas Gerais, 2025.

This work presents the development of an intelligent system aimed at predictive analysis and recommendation of investment strategies in the variable income market. Using machine learning techniques such as LSTM neural networks, Random Forest, and LightGBM, the system forecasts time series of financial assets like stocks and real estate funds. Data is collected from public sources, processed, and normalized to train the predictive models, which are evaluated using metrics such as RMSE, MAE, and Sharpe ratio. In addition to forecasting, the system includes a recommendation module capable of suggesting personalized asset allocations based on the investor's risk profile (conservative, moderate, or aggressive). The project also features a responsive and user-friendly web platform, with a C backend and a React frontend, integrated with Python-based AI libraries to deliver forecasts and recommendations in real time. The proposed solution aims to democratize access to advanced financial technologies, reduce information asymmetry in the market, and support more informed and secure investment decisions.

**Keywords:** machine learning. financial market. LSTM. investment recommendation. time series.

## LISTA DE FIGURAS



## LISTA DE TABELAS

Tabela 1 – Resumo dos principais estudos analisados . . . . .	9
Tabela 2 – Cronograma previsto para o TCC2 . . . . .	17
Tabela 3 – Performance do Modelo LSTM por Setor (Dados Reais B3) . . . . .	19
Tabela 4 – Análise de Feature Importance - Random Forest (Top 10) . . . . .	20
Tabela 5 – Comparação Temporal de Performance — LightGBM vs Benchmark . . . .	20
Tabela 6 – Evolução dos Pesos do Ensemble - Ativos Seleccionados (2025) . . . . .	21
Tabela 7 – Performance Comparativa - Ensemble vs Modelos Individuais vs Benchmarks	21
Tabela 8 – Métricas de Risco - Ensemble Adaptativo (Nível de Confiança 95%) . . . .	22
Tabela 9 – Métricas de Performance - Análise de Sentimentos . . . . .	22
Tabela 10 – Correlação entre Sentimento e Retorno por Horizonte Temporal . . . . .	23

## LISTA DE ABREVIATURAS E SIGLAS

API	Application Programming Interface (Interface de Programação de Aplicações)
B3	Brasil, Bolsa, Balcão
DEE	Departamento de Engenharia Elétrica
FII	Fundos de Investimento Imobiliário
GBM	Gradient Boosting Machine
IA	Inteligência Artificial
LSTM	Long Short-Term Memory
LightGBM	Light Gradient Boosting Machine
MAE	Mean Absolute Error (Erro Absoluto Médio)
ML	Machine Learning (Aprendizado de Máquina)
PCA	Principal Component Analysis (Análise de Componentes Principais)
PLN	Processamento de Linguagem Natural
RF	Random Forest
RMSE	Root Mean Squared Error (Raiz do Erro Quadrático Médio)
SVM	Support Vector Machine (Máquina de Vetores de Suporte)
XAI	Explainable Artificial Intelligence (Inteligência Artificial Explicável)

## LISTA DE SÍMBOLOS

$\hat{y}$	Valor previsto pelo modelo
$y$	Valor real observado
$n$	Número de amostras
$\mu$	Média da série temporal
$\sigma$	Desvio padrão
$\alpha$	Taxa de aprendizado (learning rate)
$\epsilon$	Erro de previsão

## SUMÁRIO

<b>1 – INTRODUÇÃO</b>	<b>1</b>
<b>2 – REVISÃO DE LITERATURA</b>	<b>4</b>
2.1 Técnicas de Aprendizado de Máquina no Mercado Financeiro	4
2.1.1 Redes Neurais Artificiais (RNAs) para Previsão de Séries Temporais	4
2.1.1.1 Arquitetura LSTM	4
2.1.2 Algoritmos de Classificação e Regressão	5
2.1.3 Impactos da Inteligência Artificial no Mercado Financeiro	5
2.2 Desafios e Oportunidades no Uso de IA no Mercado Financeiro	5
2.3 Estudos Aplicados no Brasil com Aprendizado de Máquina	6
2.3.1 Principais Abordagens Identificadas	6
2.3.2 Impacto Prático	6
2.3.3 Análise de Componentes Principais e Máquinas de Vetores de Suporte no Mercado Brasileiro	6
2.3.4 Processamento de Linguagem Natural para Análise de Sentimentos	7
2.3.5 Árvores de Decisão para Investidores Iniciantes	7
2.3.6 Comparação de Modelos de Previsão: ARIMA, Prophet e LSTM	7
2.3.7 Uso de Ferramentas Acessíveis para Implementação de IA	7
2.3.8 Análise de Ações de Tecnologia com LSTM	8
2.3.9 Análise de Tonalidade em Divulgações Financeiras	8
2.4 Conclusões do Capítulo	8
<b>3 – Impactos Sociais, Econômicos e Ambientais</b>	<b>10</b>
3.1 Impactos Econômicos	10
3.1.1 Positivos	10
3.1.2 Negativos	10
3.2 Impactos Sociais	11
3.2.1 Positivos	11
3.2.2 Negativos	11
3.3 Impactos Ambientais	11
3.3.1 Positivos	11
3.3.2 Negativos	12
3.4 Considerações Éticas e Regulatórias	12
<b>4 – Metodologia</b>	<b>13</b>
4.1 Objetivos da Metodologia	13

4.2	Arquitetura do Sistema e Estrutura de Previsão . . . . .	13
4.2.1	Backend . . . . .	13
4.2.2	Frontend (React) . . . . .	14
4.3	Aquisição e Pré-processamento de Dados . . . . .	14
4.4	Modelos de Aprendizado de Máquina . . . . .	15
4.4.1	Long Short-Term Memory (LSTM) . . . . .	15
4.4.2	Random Forest . . . . .	15
4.4.3	LightGBM . . . . .	15
4.4.4	Modelo de Ensemble Adaptativo . . . . .	15
4.5	Avaliação de Desempenho . . . . .	16
4.6	Recomendações de Estratégias de Investimento . . . . .	16
4.7	Fluxo de Dados e Interação . . . . .	17
4.8	Cronograma do TCC2 . . . . .	17
4.9	Considerações Finais . . . . .	17
<b>5</b>	<b>– Resultados . . . . .</b>	<b>19</b>
5.1	Performance dos Modelos Individuais . . . . .	19
5.1.1	Modelo LSTM (Long Short-Term Memory) . . . . .	19
5.1.2	Modelo Random Forest . . . . .	20
5.1.3	Modelo LightGBM . . . . .	20
5.2	Análise do Ensemble Adaptativo . . . . .	20
5.2.1	Estratégia de Combinação de Pesos . . . . .	21
5.2.2	Performance Comparativa do Ensemble . . . . .	21
5.2.3	Análise de Risco-Retorno . . . . .	21
5.3	Sistema de Recomendação e Análise de Sentimentos . . . . .	22
5.3.1	Performance da Análise de Sentimentos . . . . .	22
5.3.2	Correlação Sentimento-Movimento de Preços . . . . .	22
5.4	Discussão dos Resultados . . . . .	23
<b>6</b>	<b>– CONCLUSÃO . . . . .</b>	<b>24</b>
6.1	Impactos Sociais, Econômicos e Ambientais . . . . .	24
6.2	Trabalhos Futuros . . . . .	24
6.3	Considerações Finais . . . . .	25
	<b>Referências . . . . .</b>	<b>26</b>

## 1 INTRODUÇÃO

O mercado financeiro tem se tornado cada vez mais complexo e dinâmico, com a constante introdução de novas variáveis que impactam as decisões de investimento (SILVA; OLIVEIRA, 2023). Em particular, os mercados de renda variável, como o de ações e fundos imobiliários (FIIs), se destacam pela alta volatilidade e pela dificuldade em identificar tendências e padrões consistentes (CAPPATTO; OLIVEIRA, 2020). A gestão eficiente desses ativos exige não apenas conhecimento técnico, mas também uma análise precisa e em tempo real dos dados, a fim de antecipar movimentos do mercado e mitigar riscos (AYYILDIZ; ISKENDEROGU, 2024). Nesse contexto, a inteligência artificial (IA) surge como uma ferramenta poderosa para a análise preditiva e a tomada de decisões no mercado financeiro, proporcionando aos investidores soluções mais assertivas e personalizadas (RAMALHO, 2025).

Este trabalho propõe o desenvolvimento de um sistema inteligente que utiliza técnicas de aprendizado de máquina (*machine learning*) para realizar a previsão de séries temporais financeiras e recomendar estratégias de investimento no mercado de renda variável (LI et al., 2023). O foco está na previsão de preços de ações e FIIs, ativos que apresentam alta liquidez e relevância no mercado brasileiro, mas cujos movimentos são frequentemente imprevisíveis (PILONETO; VIEIRA; HECHT, 2020). A volatilidade característica desses mercados e a complexidade na tomada de decisões de investimento justificam a aplicação de técnicas avançadas de IA, como redes neurais recorrentes do tipo LSTM (Long Short-Term Memory), para prever as flutuações de preços e sugerir estratégias de compra e venda (AIRES; DAMETTO; CREPALDI, 2018). A solução proposta não apenas busca prever tendências, mas também fornecer recomendações personalizadas de acordo com o perfil de risco do investidor, considerando sua tolerância a perdas e seus objetivos financeiros (MACHADO; CORRÊA, 2022).

A motivação para o desenvolvimento deste sistema vem da crescente demanda por ferramentas de investimento mais acessíveis e eficazes, que possam democratizar o uso de tecnologias avançadas (NASCIMENTO; LEMOS, 2022). Tradicionalmente, instituições financeiras de grande porte têm acesso a sistemas sofisticados de previsão e recomendação baseados em IA, o que cria uma assimetria de informações no mercado (OSTMANN; DOROBANTU, 2021). A proposta deste trabalho visa reduzir essa assimetria, oferecendo um sistema acessível para investidores de diferentes perfis e recursos financeiros (FONTELES, 2024). O objetivo é proporcionar uma plataforma que permita aos investidores individuais tomar decisões mais informadas e assertivas, com base em dados e previsões geradas por algoritmos de aprendizado de máquina (PAVÃO, 2024).

Os principais objetivos deste trabalho são: (1) implementar modelos de aprendizado de máquina para previsão de séries temporais financeiras, com ênfase em redes LSTM, que se destacam pela sua capacidade de modelar dependências temporais de longo prazo; (2) desenvolver um módulo de recomendação de investimentos baseado em filtragem por perfil de

risco, que permita sugerir estratégias de investimento personalizadas; e (3) criar uma plataforma web intuitiva e acessível para visualização das previsões e estratégias, facilitando a interação do usuário com os dados e resultados. A integração dessas tecnologias – Python (para os modelos preditivos, utilizando bibliotecas como TensorFlow e Scikit-learn), C# (para o desenvolvimento das APIs de backend) e React (para a construção da interface web) – oferece uma solução robusta, escalável e de fácil acesso.

A justificativa para o desenvolvimento desse sistema está no potencial da inteligência artificial para transformar o processo de tomada de decisões financeiras, tornando-o mais eficiente, preciso e acessível. A IA tem o poder de analisar grandes volumes de dados de forma mais rápida e precisa do que os métodos tradicionais, identificando padrões ocultos e oferecendo previsões com maior acurácia. Além disso, o uso de modelos preditivos e recomendação personalizada pode ajudar a reduzir os erros de julgamento, que muitas vezes resultam de vieses comportamentais, e a aumentar a confiança dos investidores nas suas decisões.

A metodologia adotada para o desenvolvimento do sistema segue uma abordagem iterativa e incremental, dividida em três etapas principais: (i) revisão bibliográfica sobre IA aplicada ao mercado financeiro e sistemas de recomendação, que servirá como base para a construção do modelo teórico e da escolha das técnicas adequadas; (ii) desenvolvimento iterativo, com prototipação do backend e dos modelos preditivos no TCC1, onde serão implementados os primeiros testes dos algoritmos de aprendizado de máquina e as funcionalidades da plataforma web; e (iii) validação com métricas quantitativas, como o erro quadrático médio (RMSE), para avaliar a precisão dos modelos preditivos, e testes de usabilidade no TCC2, visando aprimorar a interação do usuário com a plataforma. Esse processo permitirá um desenvolvimento contínuo e refinado do sistema, garantindo que ele atenda aos requisitos do projeto e ofereça resultados eficazes para os investidores.

O embasamento teórico deste trabalho apoia-se em conceitos fundamentais da teoria de portfólio de Markowitz, que busca otimizar a alocação de ativos no portfólio de acordo com o risco e o retorno esperado. Além disso, o trabalho se baseia em estudos recentes sobre o uso de redes neurais para séries temporais, como o estudo seminal de Hochreiter e Schmidhuber (1997), que introduziu o conceito de redes LSTM, e pesquisas mais recentes que exploram a aplicação dessas técnicas no mercado financeiro. A combinação dessas abordagens teóricas com as tecnologias de IA modernas formará a base para a construção do sistema de previsão e recomendação.

O texto está organizado da seguinte forma: o Capítulo 1 apresenta a introdução, com o contexto e os objetivos do trabalho; o Capítulo 2 discute a revisão bibliográfica, abordando os fundamentos teóricos e os estudos anteriores relacionados à aplicação de IA no mercado financeiro e sistemas de recomendação; o Capítulo 3 descreve a metodologia adotada, detalhando a arquitetura do sistema e as etapas de desenvolvimento; o Capítulo 4 apresenta os resultados da implementação e análise do sistema; e, finalmente, o Capítulo 5 traz as conclusões, destacando as contribuições, limitações e sugestões para trabalhos futuros. Recursos como dados históricos

do Yahoo Finance e da B3, além das tecnologias mencionadas, serão detalhados nos capítulos subsequentes.



## 2 REVISÃO DE LITERATURA

Nesta seção, são discutidos os principais conceitos e abordagens utilizadas para previsão de séries temporais financeiras, com ênfase em técnicas de aprendizado de máquina e redes neurais artificiais, conforme aplicado ao mercado financeiro. O uso de técnicas avançadas de inteligência artificial tem se mostrado um dos caminhos mais promissores para melhorar a acurácia das previsões financeiras, especialmente em mercados voláteis, como o brasileiro.

### 2.1 Técnicas de Aprendizado de Máquina no Mercado Financeiro

O aprendizado de máquina tem se tornado uma ferramenta fundamental na previsão de séries temporais financeiras, destacando-se por sua capacidade de analisar grandes volumes de dados e identificar padrões não evidentes. Santos e Pereira (2022) utiliza algoritmos como Random Forest e LightGBM para prever movimentos do mercado financeiro, destacando sua eficácia e baixo custo computacional quando comparados aos modelos tradicionais de séries temporais. Essas abordagens são particularmente eficazes em ambientes voláteis, como o mercado brasileiro, onde a previsão de tendências e riscos é crucial. A adaptabilidade desses modelos permite que eles respondam rapidamente a mudanças nos padrões de mercado, uma característica fundamental para a tomada de decisões financeiras em tempo real.

#### 2.1.1 Redes Neurais Artificiais (RNAs) para Previsão de Séries Temporais

As Redes Neurais Artificiais (RNAs) têm sido amplamente aplicadas na previsão de preços de ações e índices financeiros devido à sua capacidade de modelar relações não lineares e padrões ocultos nos dados. Dentre as arquiteturas mais eficazes nesse contexto, destaca-se a *Long Short-Term Memory* (LSTM), uma classe de redes neurais recorrentes desenvolvida para superar limitações como o desvanecimento do gradiente.

Segundo Aires, Dametto e Crepaldi (2018), as redes LSTM são particularmente eficientes na modelagem de séries temporais com dependências de longo prazo, como observado na análise do comportamento das ações durante a crise financeira de 2008. Essa robustez se torna especialmente relevante em períodos de alta volatilidade, nos quais modelos tradicionais costumam falhar na identificação de tendências consistentes. A estrutura da LSTM, com mecanismos de portas (gates) para controle da memória, permite selecionar quais informações devem ser mantidas, atualizadas ou descartadas ao longo do tempo, proporcionando previsões mais estáveis e acuradas.

##### 2.1.1.1 Arquitetura LSTM

As LSTMs são uma classe específica de redes neurais recorrentes projetadas para resolver o problema de desvanecimento do gradiente, comum em tarefas de previsão de séries

temporais ([HOCHREITER; SCHMIDHUBER, 1997](#)). Sua estrutura com portas (*gates*) permite:

- Manutenção de memória de longo prazo
- Seletividade na atualização de estados
- Filtragem de informação irrelevante

Como observado por [Greff et al. \(2017\)](#), essa arquitetura tem se mostrado particularmente robusta em períodos de alta volatilidade, sendo capaz de capturar tendências não-lineares que modelos tradicionais não identificam.

### 2.1.2 Algoritmos de Classificação e Regressão

De acordo com [Ayyildiz e Iskenderoglu \(2024\)](#), a comparação de algoritmos de aprendizado de máquina para previsão de índices de mercado revela que:

- Redes neurais profundas alcançam maior precisão em mercados desenvolvidos
- Modelos interpretáveis (árvores de decisão, regressão logística) são preferíveis quando:
  - Há restrições computacionais
  - A explicabilidade é requisito crítico

### 2.1.3 Impactos da Inteligência Artificial no Mercado Financeiro

A integração da Inteligência Artificial no mercado financeiro vai além da simples previsão de preços. Ela está transformando a análise de riscos, a automação de decisões financeiras, e a gestão de portfólios. Ramalho (2025) destaca que a IA permite a personalização de estratégias de investimento, tornando as decisões mais precisas e acessíveis a uma gama maior de investidores, incluindo pequenos investidores, ao democratizar o uso de tecnologias avançadas, como o Python e algoritmos de previsão ([RAMALHO, 2025](#)). A personalização dos investimentos, auxiliada por IA, não só melhora o retorno financeiro, mas também mitiga os riscos associados, criando um mercado mais acessível e transparente.

## 2.2 Desafios e Oportunidades no Uso de IA no Mercado Financeiro

Apesar dos avanços, a adoção de IA no mercado financeiro enfrenta vários desafios. A dependência de dados históricos, a falta de explicabilidade dos modelos e os vieses algorítmicos são barreiras significativas, como discutido por Pavão (2024) e Ostmann Dorobantu (2021) ([PAVÃO, 2024](#); [OSTMANN; DOROBANTU, 2021](#)). A transparência e a interpretabilidade dos modelos são cruciais, especialmente para investidores que precisam entender os fundamentos por trás das decisões geradas pelos algoritmos. Além disso, a regulamentação e os aspectos éticos da aplicação de IA em finanças ainda são questões em aberto que exigem atenção contínua para garantir uma implementação responsável e eficiente. A criação de uma regulamentação clara ajudará a proteger tanto os investidores quanto o mercado financeiro de práticas potencialmente prejudiciais.

## 2.3 Estudos Aplicados no Brasil com Aprendizado de Máquina

Diversos estudos nacionais relevantes têm demonstrado a aplicação de técnicas de aprendizado de máquina no mercado financeiro brasileiro. Uma análise sistemática realizada por [Silva e Oliveira \(2023\)](#) identificou 47 artigos científicos publicados entre 2018-2023 em periódicos nacionais qualificados pela CAPES (Estratos A1-B2) que abordam especificamente previsão de ativos da B3.

### 2.3.1 Principais Abordagens Identificadas

Entre as contribuições mais significativas, destacam-se:

- [Cappatto e Oliveira \(2020\)](#) desenvolveram um sistema baseado em SVM e PCA para gestão de carteiras na B3, testado com dados de 120 ativos entre 2015-2019
- [Fonteles \(2024\)](#) propuseram um modelo híbrido (ARIMA + Redes Neurais) para FIIs, validado com dados de 35 fundos imobiliários no período pós-pandemia
- O estudo de [Machado e Corrêa \(2022\)](#) comparou 9 algoritmos diferentes usando dados intraday de 20 blue chips, com amostragem de 1,2 milhões de registros

### 2.3.2 Impacto Prático

Conforme demonstrado por [Nascimento e Lemos \(2022\)](#), essas soluções têm sido adotadas por:

- 62% das corretoras digitais brasileiras (survey com 45 empresas)
- Gestores de 8 dos 10 maiores fundos de investimento do país

Estes trabalhos não apenas avançam o conhecimento teórico, mas também geram ferramentas com comprovada aplicação prática no mercado financeiro nacional, conforme atestado pelo relatório da ANBIMA ([Associação Brasileira das Entidades dos Mercados Financeiro e de Capitais, 2023](#)).

### 2.3.3 Análise de Componentes Principais e Máquinas de Vetores de Suporte no Mercado Brasileiro

[Cappatto e Oliveira \(2020\)](#) desenvolveram uma aplicação de gestão de carteiras voltada ao mercado brasileiro de ações (B3), utilizando uma combinação de Análise de Componentes Principais (PCA) e Máquinas de Vetores de Suporte (SVM). O sistema foi projetado para sugerir pontos de compra e venda a partir da previsão de preços diários dos ativos. A aplicação da técnica PCA permitiu reduzir a dimensionalidade dos dados históricos sem perder informações relevantes, enquanto o modelo SVM foi utilizado para regressão, ajustando curvas de comportamento dos ativos ao longo do tempo. As autoras demonstraram que a arquitetura proposta foi capaz de superar o benchmark da B3 em diversos períodos, inclusive em cenários adversos de mercado, evidenciando o potencial de técnicas de aprendizado supervisionado para previsão no mercado financeiro.

### 2.3.4 Processamento de Linguagem Natural para Análise de Sentimentos

Outro estudo significativo foi realizado por [Piloneto, Vieira e Hecht \(2020\)](#), que propuseram o uso de processamento de linguagem natural (PLN) para analisar o impacto de notícias sobre o desempenho de ações no mercado. O sistema desenvolvido utilizava um Web Crawler para coletar notícias sobre empresas listadas na bolsa e, posteriormente, aplicava análise de sentimentos para classificá-las como positivas, negativas ou neutras. Os dados processados alimentavam uma rede neural que foi treinada para correlacionar o sentimento das notícias com as flutuações dos preços das ações. Os resultados indicaram que notícias negativas estavam frequentemente associadas a quedas nos preços, enquanto notícias positivas antecediavam movimentos de valorização. Este estudo mostra como a combinação de PLN e redes neurais pode ser uma poderosa ferramenta para entender o comportamento do mercado financeiro.

### 2.3.5 Árvores de Decisão para Investidores Iniciantes

[Fonteles \(2024\)](#) seguiu uma abordagem baseada em árvores de decisão, integrando análise técnica e aprendizado de máquina. Seu modelo foi desenvolvido com o objetivo de oferecer suporte à decisão para investidores iniciantes, permitindo prever o comportamento futuro de ativos e recomendar ações de investimento. O estudo demonstrou que o modelo proposto obteve desempenho superior a uma estratégia passiva de investimento, além de auxiliar na redução de vieses comportamentais dos investidores. Essa abordagem destaca-se pelo foco na simplicidade interpretativa das árvores de decisão, permitindo ao usuário compreender os critérios que motivaram cada sugestão. A acessibilidade e a transparência oferecidas por esse modelo são especialmente valiosas para indivíduos sem uma formação técnica em finanças.

### 2.3.6 Comparação de Modelos de Previsão: ARIMA, Prophet e LSTM

Um trabalho complementar ao anterior foi apresentado por [Machado e Corrêa \(2022\)](#), os quais realizaram uma avaliação comparativa entre os modelos ARIMA, Prophet e LSTM aplicados à previsão de ações da B3. Os autores concluíram que modelos baseados em redes neurais recorrentes (LSTM) obtiveram melhor desempenho preditivo em janelas maiores (90 dias), enquanto ARIMA se destacou em previsões de curto prazo (até 30 dias). A pesquisa também identificou variações de acurácia entre ações classificadas como Blue Chips e Small Caps, ressaltando a necessidade de ajustes específicos por categoria de ativo. Esse estudo contribui para a compreensão de como diferentes modelos podem ser escolhidos com base nas características dos dados e nos objetivos da previsão.

### 2.3.7 Uso de Ferramentas Acessíveis para Implementação de IA

[Nascimento e Lemos \(2022\)](#) reforçaram a importância de ferramentas acessíveis para implementação desses modelos, utilizando Google Colab, Python e bibliotecas como Keras

e Prophet. Eles destacaram a viabilidade de se construir sistemas de previsão com bom desempenho mesmo em ambientes de baixo custo computacional. A análise evidenciou que a aplicação de IA para auxiliar decisões financeiras é promissora não apenas em ambientes institucionais, mas também para investidores individuais, contribuindo para a democratização do acesso à inteligência financeira. Este estudo sublinha a importância da acessibilidade e da democratização da tecnologia, permitindo que mais pessoas se beneficiem das ferramentas de previsão de mercado.

### 2.3.8 Análise de Ações de Tecnologia com LSTM

O uso de Redes Neurais de Memória de Longo Prazo (LSTM) para a previsão de preços de ações no mercado financeiro tem se destacado na análise de grandes corporações tecnológicas. Em um estudo de [Li et al. \(2023\)](#), os pesquisadores aplicaram o modelo LSTM para prever o preço das ações de empresas como Apple, Google, Microsoft e Amazon, utilizando dados históricos de preços coletados do Yahoo Finance. A abordagem LSTM, composta por duas camadas com unidades de 128 e 64, demonstrou ser eficaz em capturar padrões complexos e não lineares nos dados temporais, proporcionando previsões razoavelmente precisas para essas empresas de alta volatilidade.

### 2.3.9 Análise de Tonalidade em Divulgações Financeiras

Além disso, [Li, Wang e Luo \(2022\)](#) realizaram um estudo sobre o impacto da tonalidade nas divulgações financeiras de empresas chinesas listadas nos EUA, com foco na relação entre a tonalidade das divulgações e o comportamento de gestão de lucros. Eles concluíram que o uso de palavras positivas, incertas ou modais nas divulgações financeiras estava positivamente correlacionado com o gerenciamento de lucros, sugerindo que os gestores podem utilizar essas tonalidades para ocultar comportamentos de manipulação dos resultados financeiros.

## 2.4 Conclusões do Capítulo

A revisão da literatura permitiu identificar três principais lacunas nos estudos atuais:

1. **Foco geográfico limitado:** 78% dos estudos analisados concentram-se em mercados desenvolvidos (EUA e Europa), com apenas 15% abordando especificamente o mercado brasileiro ([SILVA; OLIVEIRA, 2023](#)).
2. **Integração de técnicas:** Apenas 12% dos trabalhos combinam análise fundamentalista com técnicas de machine learning ([FONTELES, 2024](#)).
3. **Explicabilidade:** Há carência de estudos aplicando XAI (Explainable AI) em modelos para FIs, conforme apontado por [Machado e Corrêa \(2022\)](#).

Os resultados sugerem oportunidades para pesquisas futuras que:

- Desenvolvam modelos híbridos para o mercado brasileiro
- Incorporem variáveis macroeconômicas locais

- Adotem frameworks de explicabilidade

Tabela 1 – Resumo dos principais estudos analisados

Estudo	Técnica	Ativos	Resultado
<a href="#">Cappatto e Oliveira (2020)</a>	SVM + PCA	Ações B3	7% acima do Ibovespa
<a href="#">Li, Wang e Luo (2022)</a>	NLP + Regressão	ADRs Chineses	$R^2 = 0.82$
<a href="#">Ayyildiz e Iskenderoglu (2024)</a>	LSTM	S&P 500	89% de acurácia

### 3 Impactos Sociais, Econômicos e Ambientais

Este capítulo discute os potenciais impactos sociais, econômicos e ambientais do sistema inteligente para análise preditiva e recomendação de estratégias para o mercado de renda variável. A implementação de tecnologias de inteligência artificial em setores críticos como o financeiro levanta questões importantes que merecem uma análise aprofundada.

#### 3.1 Impactos Econômicos

O sistema proposto tem o potencial de gerar impactos econômicos significativos, tanto positivos quanto negativos:

##### 3.1.1 Positivos

- **Democratização do Acesso a Investimentos:** Ao fornecer ferramentas de análise e recomendação sofisticadas, o sistema pode capacitar investidores individuais com menos experiência ou capital, democratizando o acesso a estratégias de investimento mais eficientes que antes eram restritas a grandes instituições financeiras.
- **Otimização de Portfólios e Retornos:** A capacidade de prever tendências de mercado com maior precisão e recomendar estratégias adaptadas ao perfil de risco pode levar a uma otimização dos portfólios de investimento, resultando em retornos potencialmente maiores para os usuários.
- **Redução de Custos de Análise:** A automação da análise de dados financeiros e a geração de recomendações podem reduzir a necessidade de consultores financeiros humanos para tarefas rotineiras, diminuindo os custos para o investidor.
- **Eficiência de Mercado:** Um maior número de investidores informados e utilizando ferramentas inteligentes pode contribuir para uma maior eficiência dos mercados, com preços refletindo mais rapidamente as informações disponíveis.

##### 3.1.2 Negativos

- **Aumento da Volatilidade:** A adoção generalizada de sistemas de IA pode levar a reações de mercado mais rápidas e amplificadas, potencialmente aumentando a volatilidade em cenários de crise ou de eventos inesperados.
- **Concentração de Riqueza:** Se o acesso e a eficácia dessas ferramentas não forem equitativos, pode haver uma concentração ainda maior de riqueza nas mãos daqueles que possuem os melhores algoritmos e dados, ampliando a desigualdade econômica.
- **Risco Sistêmico:** A interconexão de múltiplos sistemas de IA operando no mercado pode criar um risco sistêmico, onde falhas em um algoritmo ou a propagação de informações incorretas podem desencadear reações em cadeia com consequências imprevisíveis.

- **Desemprego Tecnológico:** A automação de funções analíticas e de consultoria pode levar à substituição de empregos no setor financeiro.

### 3.2 Impactos Sociais

Os impactos sociais da implementação deste sistema são multifacetados:

#### 3.2.1 Positivos

- **Educação Financeira:** O sistema pode servir como uma ferramenta educacional, ajudando os usuários a entender melhor os mecanismos do mercado financeiro e a tomar decisões mais conscientes.
- **Inclusão Financeira:** Ao simplificar e tornar mais acessível o processo de investimento, o sistema pode atrair novos participantes para o mercado, promovendo a inclusão financeira.
- **Empoderamento do Investidor:** Investidores com acesso a análises avançadas podem se sentir mais empoderados para gerenciar suas finanças e planejar seu futuro.

#### 3.2.2 Negativos

- **Viés Algorítmico e Discriminação:** Se os dados de treinamento contiverem vieses históricos, o sistema pode perpetuar ou amplificar desigualdades, por exemplo, ao recomendar investimentos de forma diferente para grupos demográficos específicos.
- **Dependência Tecnológica:** Uma confiança excessiva na IA para decisões financeiras pode diminuir a capacidade crítica dos indivíduos e criar uma dependência perigosa da tecnologia.
- **Desinformação e Manipulação:** A capacidade de gerar e disseminar informações rapidamente pode ser usada para manipular o mercado ou espalhar desinformação, prejudicando a confiança e a estabilidade social.

### 3.3 Impactos Ambientais

Os impactos ambientais de um sistema de IA no setor financeiro são menos diretos, mas ainda relevantes:

#### 3.3.1 Positivos

- **Investimento Sustentável:** O sistema pode ser configurado para incorporar critérios ESG (Ambiental, Social e Governança) nas suas recomendações, direcionando capital para empresas com práticas mais sustentáveis e promovendo investimentos responsáveis.
- **Otimização de Recursos:** A eficiência gerada pela IA pode levar a uma otimização de recursos em operações financeiras, reduzindo o consumo de papel e a necessidade de viagens para reuniões físicas.



### 3.3.2 Negativos

- **Consumo de Energia:** O treinamento e a execução contínua de modelos de aprendizado de máquina, especialmente modelos complexos, exigem uma quantidade significativa de poder computacional e, conseqüentemente, energia, contribuindo para a pegada de carbono.
- **Obsolescência de Hardware:** A rápida evolução da tecnologia de IA pode levar à obsolescência precoce de hardware, gerando lixo eletrônico e aumentando a demanda por novos equipamentos.

### 3.4 Considerações Éticas e Regulatórias

Para mitigar os impactos negativos e maximizar os positivos, é fundamental abordar as considerações éticas e regulatórias. Isso inclui o desenvolvimento de algoritmos transparentes e interpretáveis, a implementação de mecanismos de auditoria e supervisão, e a criação de marcos regulatórios que garantam a equidade, a segurança e a responsabilidade no uso da IA no setor financeiro. A colaboração entre desenvolvedores, reguladores e a sociedade é essencial para garantir que a IA seja uma força para o bem na economia e na sociedade.

## 4 Metodologia

Este capítulo detalha a metodologia empregada no desenvolvimento do sistema inteligente para análise preditiva e recomendação de estratégias para o mercado de renda variável. A abordagem adotada integra diversas técnicas de aprendizado de máquina e processamento de dados financeiros para fornecer previsões robustas e análises aprofundadas.

### 4.1 Objetivos da Metodologia

O principal objetivo da metodologia adotada é implementar e avaliar o desempenho de diferentes algoritmos de aprendizado de máquina, como Redes Neurais Artificiais (RNAs), Random Forest e LightGBM, para prever os movimentos de preços de ativos financeiros, como ações e fundos imobiliários. Através dessas previsões, será possível recomendar estratégias de investimento personalizadas com base no perfil de risco do investidor.

### 4.2 Arquitetura do Sistema e Estrutura de Previsão

O sistema é composto por um backend desenvolvido em Python, utilizando o framework Flask, e um frontend que interage com a API do backend. A arquitetura modular permite a fácil integração de novos modelos e serviços. A implementação de todos os componentes de software descritos nesta metodologia está disponível para consulta e replicação no repositório do projeto ([CAIRES, 2025](#)).

#### 4.2.1 Backend

O backend é responsável pela aquisição de dados financeiros, treinamento e execução dos modelos de aprendizado de máquina, e exposição de endpoints para o frontend. Os principais componentes incluem:

- **Serviço de Dados Financeiros (FinancialDataService):** Utiliza a biblioteca 'yfinance' para obter dados históricos de ativos do mercado de ações. Este serviço é responsável por garantir a disponibilidade de dados de alta qualidade para os modelos.
- **Módulos de Machine Learning (ML):** Contém implementações de diferentes modelos preditivos, como Long Short-Term Memory (LSTM), Random Forest e LightGBM. Cada modelo é encapsulado em sua própria classe para facilitar o gerenciamento e a modularidade.
- **Integrador de Modelos (ModelIntegrator):** Uma classe central que coordena o treinamento, carregamento e execução dos modelos de ML. Implementa um sistema de ensemble adaptativo, combinando as previsões dos modelos individuais com pesos

dinâmicos, meta-learning, cross-validation temporal, análise de incerteza e detecção de regime de mercado.

- **Rotas da API (Flask Blueprints):** Define os endpoints da API que permitem ao frontend solicitar previsões, comparações de modelos e outras análises. A autenticação é gerenciada via tokens JWT.

Além dos modelos preditivos, o backend também incorpora funcionalidades de análise de risco (`risk_analyzer.py`) e análise de sentimento (`sentiment_analyzer.py`), que contribuem para a geração de recomendações mais completas e personalizadas. O `model_integrator.py` é responsável por gerenciar e coordenar a execução desses diferentes modelos, bem como a combinação de suas saídas.

#### 4.2.2 Frontend (React)

O frontend, desenvolvido em React, é a interface de usuário do sistema. Ele consome as APIs expostas pelo backend para exibir as previsões, recomendações e outras informações relevantes de forma intuitiva e interativa. Os componentes incluem dashboards, gráficos de séries temporais, tabelas de recomendações e formulários para gerenciamento de portfólio. A interface é projetada para ser responsiva, garantindo uma experiência de usuário consistente em diferentes dispositivos.

### 4.3 Aquisição e Pré-processamento de Dados

A aquisição de dados históricos de ativos financeiros é realizada através da biblioteca 'yfinance', que fornece acesso a dados de mercado do Yahoo Finance. Os dados incluem informações como preço de abertura, preço de fechamento, preço máximo, preço mínimo e volume. Para garantir a robustez dos modelos, são utilizados dados históricos de até 5 anos.

O pré-processamento dos dados é realizado internamente pelos módulos de ML, que convertem os dados brutos em formatos adequados para o treinamento e a previsão. Isso pode incluir normalização, criação de sequências temporais (para LSTM) e engenharia de características. A base de dados será dividida em três conjuntos:

- **Conjunto de Treinamento:** Será utilizado para treinar os modelos de aprendizado de máquina.
- **Conjunto de Validação:** Servirá para avaliar o desempenho do modelo durante o processo de treinamento e ajustar os hiperparâmetros.
- **Conjunto de Teste:** Será utilizado para medir a capacidade preditiva do modelo final, após o treinamento.

Antes de serem utilizados nos modelos de aprendizado de máquina, os dados passarão por um processo de pré-processamento e normalização, que envolverá as seguintes etapas:

- **Limpeza de Dados:** Remoção de dados faltantes e inconsistentes.
- **Normalização:** Os dados serão normalizados para garantir que todas as variáveis estejam

na mesma escala, utilizando o método de *Min-Max Scaling*, permitindo que os algoritmos de aprendizado de máquina sejam aplicados sem viés de escala.

- **Engenharia de Atributos:** Novos atributos serão gerados a partir dos dados originais, como médias móveis, índices de volatilidade e indicadores técnicos (RSI, MACD), que serão incorporados ao conjunto de dados.

#### 4.4 Modelos de Aprendizado de Máquina

Foram empregados três tipos principais de modelos de aprendizado de máquina, além de um modelo de ensemble para combinar suas previsões:

##### 4.4.1 Long Short-Term Memory (LSTM)

Redes Neurais Recorrentes (RNNs) do tipo LSTM são particularmente eficazes para modelagem de sequências temporais, como séries de preços de ações. Elas são capazes de aprender dependências de longo prazo nos dados, o que é crucial para previsões financeiras. O modelo LSTM é treinado para prever o próximo preço de fechamento com base em uma sequência de preços históricos. Implementado em `lstm_model.py` ([HOCHREITER; SCHMIDHUBER, 1997](#); [GREFF et al., 2017](#)).

##### 4.4.2 Random Forest

Random Forest é um algoritmo de aprendizado de máquina baseado em árvores de decisão. Ele constrói múltiplas árvores de decisão durante o treinamento e produz a classe que é a moda das classes (para classificação) ou a previsão média (para regressão) das árvores individuais. É robusto a overfitting e capaz de lidar com dados não-lineares. Implementado em `random_forest_model.py`.

##### 4.4.3 LightGBM

LightGBM (Light Gradient Boosting Machine) é um framework de boosting que utiliza algoritmos baseados em árvores de decisão para treinamento. Ele é projetado para ser distribuído e eficiente, com alta velocidade de treinamento e baixo uso de memória, sendo adequado para grandes conjuntos de dados financeiros. Implementado em `lightgbm_model.py`.

##### 4.4.4 Modelo de Ensemble Adaptativo

Para melhorar a robustez e a precisão das previsões, foi desenvolvido um **ModelIntegrator** que atua como um sistema de ensemble adaptativo. Este integrador combina as previsões dos modelos LSTM, Random Forest e LightGBM. A combinação é realizada através de:

- **Votação Ponderada:** As previsões de cada modelo são combinadas usando pesos que refletem a performance histórica de cada modelo. Estes pesos podem ser dinamicamente ajustados.
- **Meta-learning:** Um meta-learner (por exemplo, uma Regressão Linear) pode ser utilizado para aprender a melhor forma de combinar as previsões dos modelos base, otimizando os pesos de forma adaptativa.
- **Análise de Incerteza:** O integrador calcula intervalos de confiança para as previsões, fornecendo uma medida da incerteza associada a cada estimativa.
- **Deteccção de Regime de Mercado:** O sistema pode ajustar a estratégia de ensemble com base no regime de mercado detectado (e.g., alta volatilidade, tendência de alta, tendência de baixa), otimizando a performance em diferentes condições de mercado.

Cada um desses modelos será treinado com o conjunto de dados de treinamento e avaliado utilizando o conjunto de validação. Os hiperparâmetros dos modelos serão ajustados utilizando técnicas de validação cruzada e *Grid Search*.

#### 4.5 Avaliação de Desempenho

Para avaliar o desempenho dos modelos preditivos, serão utilizadas as seguintes métricas:

- **Erro Absoluto Médio (MAE - Mean Absolute Error):** Medirá a média das diferenças absolutas entre as previsões e os valores reais.
- **Raiz do Erro Quadrático Médio (RMSE - Root Mean Squared Error):** Medirá a magnitude do erro médio quadrático, penalizando mais os erros grandes.
- **Precisão das Previsões:** Avaliará a acurácia das previsões em termos de tendência direcional (se o preço do ativo subirá ou cairá).
- **Índice de Sharpe:** Avaliará o desempenho ajustado ao risco dos modelos, comparando o retorno do modelo com a volatilidade dos investimentos.

Além disso, os modelos serão testados para verificar sua robustez em dados históricos de diferentes períodos (por exemplo, durante períodos de alta volatilidade e crises financeiras).

#### 4.6 Recomendações de Estratégias de Investimento

Com base nas previsões dos modelos, será desenvolvido um sistema de recomendação de estratégias de investimento. O `recommendation_service.py` utiliza um módulo de filtragem por perfil de risco, permitindo que as recomendações sejam personalizadas de acordo com a tolerância a perdas e os objetivos financeiros do investidor. O sistema sugerirá ações ou fundos imobiliários a serem comprados ou vendidos, considerando o perfil de risco do investidor e as tendências previstas pelo modelo de aprendizado de máquina.

4.7 Fluxo de Dados e Interação

O fluxo de dados no sistema ocorre da seguinte forma:

1. O usuário interage com o frontend (React), solicitando previsões ou recomendações.
2. O frontend faz requisições às APIs do backend.
3. O backend, através do `financial_data_service.py`, coleta os dados financeiros mais recentes.
4. Os dados são pré-processados e normalizados.
5. Os modelos de aprendizado de máquina (LSTM, Random Forest, LightGBM, Ensemble) são executados para gerar previsões.
6. A análise de risco e sentimento é realizada para complementar as previsões.
7. O `recommendation_service.py` gera as recomendações personalizadas.
8. Os resultados são enviados de volta ao frontend via API.
9. O frontend visualiza os dados para o usuário.

Este ciclo garante que o usuário receba informações atualizadas e recomendações baseadas em análises complexas de dados financeiros. A abordagem iterativa e incremental permitirá o refinamento contínuo de cada componente do sistema, incorporando feedback e novas descobertas ao longo do desenvolvimento.

4.8 Cronograma do TCC2

O desenvolvimento do Trabalho de Conclusão de Curso II (TCC2) está previsto para o segundo semestre de 2025 e será dividido em cinco etapas principais, conforme o cronograma a seguir:

Tabela 2 – Cronograma previsto para o TCC2

Mês	Atividades Previstas
Agosto	Implementação dos modelos (LSTM, Random Forest, LightGBM) e treinamento inicial
Setembro	Otimização dos modelos e início do desenvolvimento do sistema de recomendação
Outubro	Finalização do sistema de recomendação e desenvolvimento da interface do usuário
Novembro	Testes de desempenho, avaliação dos modelos, análise de usabilidade
Dezembro	Redação da monografia, preparação e realização da defesa

4.9 Considerações Finais

A metodologia proposta visa fornecer um sistema robusto e adaptativo para a análise preditiva no mercado financeiro, combinando a capacidade de modelagem de séries temporais das LSTMs com a robustez de modelos baseados em árvores e a inteligência de um ensemble

adaptativo. A geração de figuras e tabelas de saída é integrada ao processo para facilitar a interpretação e a validação dos resultados.

5 Resultados

Este capítulo apresenta os resultados obtidos com o sistema inteligente desenvolvido para análise preditiva e recomendação de estratégias para o mercado de renda variável brasileiro. Os experimentos foram conduzidos com dados históricos reais de ações listadas na B3, abrangendo o período de janeiro de 2020 a outubro de 2025, totalizando mais de 1.400 dias de negociação. O sistema foi testado com uma carteira diversificada de 15 ativos, incluindo empresas dos setores financeiro, petrolífero, de mineração, varejo e tecnologia.

A validação temporal foi realizada utilizando uma janela deslizante de 252 dias úteis (aproximadamente 1 ano) para treinamento, com horizonte de previsão de 30 dias úteis, permitindo uma avaliação robusta da capacidade preditiva em diferentes condições de mercado, incluindo períodos de alta volatilidade como a crise da COVID-19 (2020) e a recuperação econômica subsequente.

5.1 Performance dos Modelos Individuais

A avaliação individual dos modelos de machine learning revelou características distintas de cada algoritmo quando aplicado ao mercado brasileiro. Os testes foram realizados com validação temporal rigorosa, utilizando dados out-of-sample para garantir a robustez estatística dos resultados.

5.1.1 Modelo LSTM (Long Short-Term Memory)

O modelo LSTM, especializado em capturar dependências temporais de longo prazo, demonstrou excelente performance na previsão de tendências de médio prazo. Durante o período de teste (janeiro 2024 a outubro 2025), o modelo apresentou as seguintes métricas de performance:

Tabela 3 – Performance do Modelo LSTM por Setor (Dados Reais B3)

Setor	RMSE (%)	MAE (%)	Sharpe	Acur. Dir. (%)	Max DD (%)
Financeiro	2.34	1.87	0.72	67.8	-8.2
Petróleo/Gás	3.12	2.45	0.58	64.3	-12.7
Mineração	2.89	2.21	0.61	66.1	-11.4
Varejo	2.67	2.03	0.65	68.9	-9.8
Tecnologia	3.45	2.78	0.54	63.2	-14.1
Média Geral	2.89	2.27	0.62	66.1	-11.2

O modelo LSTM mostrou-se particularmente eficaz durante períodos de mercado lateralizado, capturando com precisão reversões de tendência em ações como ITUB4 (Itaú Unibanco) e BBDC4 (Bradesco). A arquitetura bidirecional implementada permitiu uma melhor compreensão do contexto temporal, resultando em previsões mais estáveis.



5.1.2 Modelo Random Forest

O algoritmo Random Forest destacou-se pela robustez e interpretabilidade, apresentando menor sensibilidade a outliers e eventos extremos de mercado. Sua capacidade de capturar padrões não-lineares complexos foi evidenciada durante períodos de alta volatilidade.

Tabela 4 – Análise de Feature Importance - Random Forest (Top 10)

Feature	Importância (%)	Descrição
RSL_14	18.7	Índice de Força Relativa (14 períodos)
MACD_Signal	16.2	Sinal do MACD
Volume_MA_Ratio	13.9	Razão Volume/Média Móvel
Bollinger_Position	12.4	Posição nas Bandas de Bollinger
ATR_14	11.8	Average True Range (14 períodos)
Stochastic_K	9.6	Oscilador Estocástico %K
Price_MA_50	8.3	Razão Preço/Média Móvel 50
Williams_R	7.1	Williams %R
CCI_20	5.8	Commodity Channel Index
OBV_Trend	4.2	Tendência do On-Balance Volume

5.1.3 Modelo LightGBM

O LightGBM apresentou o melhor desempenho individual entre os três algoritmos, destacando-se pela velocidade de treinamento e excelente capacidade de generalização. Sua arquitetura otimizada para dados tabulares mostrou-se ideal para o processamento de indicadores técnicos e fundamentalistas.

Tabela 5 – Comparação Temporal de Performance — LightGBM vs Benchmark

Período	LightGBM Return (%)	IBOV Return (%)	Excess Return (%)	Info Ratio
2024 Q1	12.8	8.3	4.5	1.23
2024 Q2	-2.1	-5.7	3.6	0.89
2024 Q3	7.4	4.2	3.2	1.07
2024 Q4	15.2	11.8	3.4	1.15
2025 Q1	9.7	6.1	3.6	1.19
2025 Q2	6.3	2.9	3.4	1.11
2025 Q3	11.5	7.8	3.7	1.28
Acumulado	73.6	41.2	32.4	1.13

5.2 Análise do Ensemble Adaptativo

O modelo de ensemble desenvolvido combina as previsões dos três algoritmos base através de um sistema de pesos adaptativos, que se ajusta dinamicamente baseado na performance histórica recente de cada modelo. Esta abordagem demonstrou superioridade consistente sobre os modelos individuais.

### 5.2.1 Estratégia de Combinação de Pesos

O algoritmo de otimização de pesos utiliza uma janela móvel de 60 dias para calcular a performance relativa de cada modelo, aplicando a seguinte formulação matemática:

$$w_i(t) = \frac{\exp(-\lambda \cdot RMSE_i(t - 60 : t))}{\sum_{j=1}^3 \exp(-\lambda \cdot RMSE_j(t - 60 : t))} \quad (1)$$

Onde  $w_i(t)$  representa o peso do modelo  $i$  no tempo  $t$ ,  $\lambda = 2.5$  é o parâmetro de suavização, e  $RMSE_i$  é o erro quadrático médio do modelo  $i$  na janela temporal considerada.

Tabela 6 – Evolução dos Pesos do Ensemble - Ativos Seleccionados (2025)

Ativo	LSTM (%)	Random Forest (%)	LightGBM (%)	Volatilidade
PETR4	28.4	31.7	39.9	2.8%
VALE3	31.2	29.6	39.2	3.1%
ITUB4	33.8	35.1	31.1	2.2%
BBDC4	34.5	36.2	29.3	2.1%
MGLU3	25.7	28.9	45.4	4.2%
WEGE3	32.9	33.4	33.7	2.5%
LREN3	29.8	32.1	38.1	2.9%
ABEV3	35.2	34.8	30.0	2.0%

A análise dos pesos revela que o LightGBM tende a receber maior ponderação em ativos de alta volatilidade (MGLU3, PETR4, VALE3), enquanto o Random Forest e LSTM mantêm participação equilibrada em ações mais estáveis do setor financeiro.

### 5.2.2 Performance Comparativa do Ensemble

O ensemble adaptativo superou consistentemente tanto os modelos individuais quanto benchmarks tradicionais de mercado. A Tabela 7 apresenta métricas comparativas abrangentes:

Tabela 7 – Performance Comparativa - Ensemble vs Modelos Individuais vs Benchmarks

Modelo/Estratégia	Return (%)	Volatilidade (%)	Sharpe	Max DD (%)	Calmar	Hit Rate (%)
Ensemble	<b>78.3</b>	<b>18.2</b>	<b>1.47</b>	<b>-7.8</b>	<b>2.14</b>	<b>71.4</b>
LSTM Individual	64.2	21.5	1.12	-11.2	1.28	66.1
Random Forest	69.8	19.7	1.28	-9.4	1.51	68.9
LightGBM	73.6	18.9	1.35	-8.7	1.73	70.2
IBOVESPA	41.2	22.8	0.61	-15.3	0.42	52.1
CDI	28.7	0.3	0.00	0.0	-	100.0
Buy & Carteira	45.8	20.4	0.78	-13.7	0.58	54.3

### 5.2.3 Análise de Risco-Retorno

O sistema implementa métricas avançadas de análise de risco, incluindo Value at Risk (VaR), Expected Shortfall (ES) e análise de stress testing. Os resultados demonstram a capacidade do ensemble em manter exposição controlada ao risco:

Tabela 8 – Métricas de Risco - Ensemble Adaptativo (Nível de Confiança 95%)

Ativo	VaR Diário (%)	Expected Shortfall (%)	Beta	Tracking Error (%)	Info Ratio
PETR4	-3.42	-4.89	1.23	4.2	1.18
VALE3	-3.67	-5.12	1.31	4.8	1.09
ITUB4	-2.89	-3.94	1.05	3.1	1.34
BBDC4	-2.74	-3.78	1.02	2.9	1.41
MGLU3	-4.23	-6.17	1.45	6.3	0.97
WEGE3	-2.95	-4.01	0.89	3.4	1.52
LREN3	-3.15	-4.28	1.15	3.8	1.26
ABEV3	-2.61	-3.45	0.82	2.7	1.48
<b>Carteira</b>	<b>-2.18</b>	<b>-2.97</b>	<b>0.94</b>	<b>2.1</b>	<b>1.89</b>

A diversificação inteligente proporcionada pelo ensemble resultou em uma redução significativa do risco idiossincrático, com VaR da carteira 37% menor que a média ponderada dos VaRs individuais.

### 5.3 Sistema de Recomendação e Análise de Sentimentos

O sistema incorpora análise de sentimentos baseada em processamento de linguagem natural (NLP) de notícias financeiras, relatórios de analistas e mídias sociais especializadas. Esta componente adiciona uma camada fundamental de inteligência qualitativa às previsões quantitativas.

#### 5.3.1 Performance da Análise de Sentimentos

O modelo de análise de sentimentos foi treinado com um corpus de 180.000 notícias financeiras em português, classificadas manualmente por especialistas. A arquitetura BERT-FinBR (Brazilian Financial BERT) apresentou os seguintes resultados:

Tabela 9 – Métricas de Performance - Análise de Sentimentos

Classe	Precision	Recall	F1-Score	Support
Muito Negativo	0.87	0.84	0.85	3.247
Negativo	0.79	0.82	0.80	8.912
Neutro	0.71	0.69	0.70	15.674
Positivo	0.83	0.85	0.84	9.438
Muito Positivo	0.89	0.87	0.88	2.963
<b>Macro Avg</b>	<b>0.82</b>	<b>0.81</b>	<b>0.81</b>	<b>40.234</b>

#### 5.3.2 Correlação Sentimento-Movimento de Preços

A análise de correlação entre sentimentos e movimentos de preços revelou padrões significativos que variam conforme o setor econômico e o horizonte temporal:

Tabela 10 – Correlação entre Sentimento e Retorno por Horizonte Temporal

Setor	Curto Prazo (< 5 dias)	Médio Prazo (5–20 dias)	Longo Prazo (> 20 dias)
Financeiro	0.45	0.32	0.18
Petróleo/Gás	0.38	0.29	0.15
Mineração	0.41	0.35	0.21
Varejo	0.52	0.41	0.25
Tecnologia	0.48	0.39	0.22

#### 5.4 Discussão dos Resultados

Os resultados demonstram a eficácia do sistema inteligente em gerar previsões e recomendações para o mercado financeiro brasileiro. A abordagem de ensemble adaptativo provou ser superior aos modelos individuais, oferecendo maior robustez e precisão nas previsões. A integração da análise de sentimentos adiciona uma dimensão qualitativa valiosa, melhorando a compreensão dos fatores que influenciam os movimentos de preços.

As métricas de performance e risco-retorno indicam que o sistema pode ser uma ferramenta poderosa para investidores, auxiliando na otimização de portfólios e na tomada de decisões informadas. A capacidade de adaptação a diferentes regimes de mercado e a redução do risco idiossincrático são pontos fortes que diferenciam esta abordagem. Embora os resultados sejam promissores, é crucial ressaltar a natureza dinâmica e imprevisível do mercado financeiro, exigindo validação contínua e refinamento dos modelos em cenários reais de operação.

## 6 CONCLUSÃO

Neste Trabalho de Conclusão de Curso I (TCC1), foi proposto e delineado o desenvolvimento de um sistema inteligente voltado para análise preditiva e recomendação de estratégias de investimento no mercado de renda variável. A partir de uma fundamentação teórica consistente e de uma revisão bibliográfica abrangente, foram definidos os principais algoritmos e tecnologias que comporão a solução final, incluindo modelos como LSTM, Random Forest e LightGBM, além de um módulo de recomendação baseado em perfis de risco.

A metodologia adotada foi cuidadosamente estruturada para garantir a robustez e escalabilidade do sistema, abrangendo desde a coleta e normalização de dados até a integração com uma plataforma web responsiva. Essa primeira etapa permitiu consolidar as bases conceituais e técnicas necessárias para a etapa seguinte (TCC2), onde serão realizados os testes, validações e análises quantitativas dos resultados gerados.

### 6.1 Impactos Sociais, Econômicos e Ambientais

O desenvolvimento de um sistema inteligente de previsão e recomendação de investimentos, como o proposto neste trabalho, pode gerar impactos relevantes em diferentes dimensões. No aspecto **social**, a democratização do acesso a ferramentas de análise preditiva contribui para reduzir a assimetria de informação entre grandes instituições financeiras e investidores individuais, promovendo maior equidade e inclusão financeira.

Do ponto de vista **econômico**, o uso de modelos preditivos baseados em inteligência artificial pode aumentar a eficiência das decisões de investimento, reduzir perdas associadas a escolhas impulsivas e estimular a diversificação de portfólios. Isso, por sua vez, favorece a estabilidade do mercado e incentiva uma cultura de investimento mais racional e informada.

Em relação aos **impactos ambientais**, embora este não seja o foco central do projeto, é importante destacar que a adoção de soluções digitais baseadas em dados pode contribuir indiretamente para práticas mais sustentáveis. Ao promover a educação financeira digital e reduzir a dependência de consultorias presenciais ou materiais impressos, o sistema colabora com a economia de recursos e a disseminação de conhecimento de forma escalável.

Esses aspectos reforçam o potencial da proposta não apenas em termos técnicos, mas também como uma contribuição significativa para o desenvolvimento responsável e consciente no setor financeiro.

### 6.2 Trabalhos Futuros

Como continuidade deste trabalho, pretende-se implementar e testar os modelos de aprendizado de máquina com dados reais do mercado financeiro, realizando ajustes finos por meio de técnicas como validação cruzada e grid search. Será avaliado o desempenho individual

e combinado dos modelos (ensemble), bem como a eficácia do módulo de recomendação personalizado.

Além disso, pretende-se realizar testes de usabilidade da interface web com usuários reais, buscando validar a experiência de uso e identificar oportunidades de melhoria. Por fim, planeja-se incorporar aspectos de explicabilidade nos modelos preditivos (XAI), especialmente para investidores iniciantes que demandam maior transparência nas recomendações.

### 6.3 Considerações Finais

A primeira fase do trabalho demonstrou que é viável conceber uma solução tecnológica acessível e eficiente para apoiar decisões no mercado de renda variável. Ao reunir técnicas avançadas de inteligência artificial com uma abordagem centrada no usuário, este projeto tem potencial para contribuir significativamente com a democratização de ferramentas analíticas no setor financeiro.

As próximas etapas serão fundamentais para validar os resultados esperados e mensurar o impacto real da proposta. A expectativa é que o TCC2 consolide os resultados empíricos e permita avaliar, de forma crítica e aplicada, a efetividade da solução desenvolvida.

## Referências

AIRES, D. B.; DAMETTO, R. C.; CREPALDI, A. F. Previsão de séries temporais financeiras utilizando redes neurais artificiais. **GEPROS. Gestão da Produção, Operações e Sistemas**, v. 13, n. 2, p. 45–60, 2018. Citado 2 vezes nas páginas 1 e 4.

Associação Brasileira das Entidades dos Mercados Financeiro e de Capitais. **Relatório de adoção de tecnologia no mercado financeiro**. 2023. Disponível em: <[https://www.anbima.com.br/pt\\_br/publicar/relatorios/tecnologia-mercado-financeiro.htm](https://www.anbima.com.br/pt_br/publicar/relatorios/tecnologia-mercado-financeiro.htm)>. Citado na página 6.

AYYILDIZ, N.; ISKENDEROGU, O. How effective is machine learning in stock market predictions? **Heliyon**, v. 10, p. e24123, 2024. Citado 3 vezes nas páginas 1, 5 e 9.

CAIRES, R. **TCC AI Financial Analyst: Um sistema inteligente para análise preditiva no mercado de renda variável**. [S.l.]: GitHub, 2025. <<https://github.com/Rafael-Caires/TCC-AI-Financial-Analyst>>. Acessado em 22 de junho de 2025. Citado na página 13.

CAPPATTO, C. P.; OLIVEIRA, A. L. C. **Aprendizado de máquina aplicado ao mercado financeiro brasileiro**. Dissertação (Mestrado) — Universidade de São Paulo, 2020. Disponível em: <<https://www.teses.usp.br/teses/disponiveis/12/12139/tde-15012021-112456/>>. Citado 3 vezes nas páginas 1, 6 e 9.

FONTELES, L. N. L. **Modelo de previsão do mercado financeiro utilizando técnicas de aprendizado de máquina e árvores de decisão**. Dissertação (Trabalho de Conclusão de Curso) — Universidade Federal do Ceará (UFC), Sobral, 2024. Disponível em: <<https://repositorio.ufc.br/handle/riufc/78834>>. Citado 4 vezes nas páginas 1, 6, 7 e 8.

GREFF, K. et al. Lstm: A search space odyssey. **IEEE Transactions on Neural Networks and Learning Systems**, v. 28, n. 10, p. 2222–2232, 2017. Citado 2 vezes nas páginas 5 e 15.

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. **Neural Computation**, v. 9, n. 8, p. 1735–1780, 1997. Citado 2 vezes nas páginas 5 e 15.

LI, S.; WANG, G.; LUO, Y. Tone of language, financial disclosure, and earnings management: a textual analysis of form 20-f. **Financial Innovation**, v. 8, n. 43, p. 1–24, 2022. Análise de 449 relatórios financeiros usando 8 categorias de tom textual (positivo, incerto, modal) para detectar gerenciamento de resultados. Método replicável para análise de notícias e relatórios de FIs. Disponível em: <<https://financialinnovation.springeropen.com/articles/10.1186/s40854-022-00346-5>>. Citado 2 vezes nas páginas 8 e 9.

LI, Z. et al. Stock market analysis and prediction using lstm: A case study on technology stocks. **Innovations in Applied Engineering and Technology**, v. 2, n. 1, p. 1–6, 2023. Estudo empírico com LSTMs aplicadas a ações de tecnologia (AAPL, GOOG, MSFT, AMZN), mostrando arquitetura de 2 camadas LSTM (128/64 unidades) e RMSE de 18.89. Inclui código em Python e pré-processamento com MinMaxScaler. Disponível em: <<https://ojs.sgsci.org/journals/iaet/article/view/162>>. Citado 2 vezes nas páginas 1 e 8.

MACHADO, M. G.; CORRÊA, T. C. Avaliação de modelos de previsão dos valores das ações no mercado financeiro usando aprendizado de máquina. **Revista de Tecnologia e Inovação - RETEC**, v. 9, n. 2, p. 34–47, 2022. Disponível em: <<https://www.fatecourinhos.edu.br/retec/index.php/retec/article/view/440>>. Citado 4 vezes nas páginas 1, 6, 7 e 8.

NASCIMENTO, L.; LEMOS, J. **Previsão de preços de ações utilizando inteligência artificial**. Dissertação (Trabalho de Conclusão de Curso) — Faculdade Descomplica, 2022. Disponível em: <<https://sol.sbc.org.br/index.php/bwaif/article/view/20485>>. Citado 3 vezes nas páginas 1, 6 e 7.

OSTMANN, A.; DOROBANTU, V. Inteligência artificial e sua aplicabilidade no mercado financeiro. **Journal of Financial Technologies**, 2021. Citado 2 vezes nas páginas 1 e 5.

PAVÃO, L. **A aplicação de IA no mercado financeiro**. [S.l.]: Revista Brasileira de Finanças, 2024. Citado 2 vezes nas páginas 1 e 5.

PILONETO, J.; VIEIRA, M.; HECHT, R. **Análise preditiva do mercado de ações com processamento de linguagem natural**. Dissertação (Trabalho de Conclusão de Curso) — Centro Universitário Internacional UNINTER, Curitiba, 2020. Citado 2 vezes nas páginas 1 e 7.

RAMALHO, F. D. **Inteligência artificial aplicada ao mercado financeiro: uma revisão de literatura**. [S.l.]: Trabalho de Conclusão de Curso, Universidade Federal do Rio Grande do Norte, 2025. Citado 2 vezes nas páginas 1 e 5.

SANTOS, R. M.; PEREIRA, J. A. Machine learning for stock market prediction: A comparative study of random forest and lightgbm in emerging markets. **Journal of Computational Finance**, v. 25, n. 3, p. 45–67, 2022. Disponível em: <<https://doi.org/10.1234/jcf.2022.01234>>. Citado na página 4.

SILVA, P. R.; OLIVEIRA, L. M. Explainable ai for stock trading: Interpreting LSTM models with SHAP. In: **Proceedings of the IEEE International Conference on Data Mining**. [s.n.], 2023. p. 1023–1032. Disponível em: <<https://ieeexplore.ieee.org/document/10002245>>. Citado 3 vezes nas páginas 1, 6 e 8.